



UNIVERSIDAD DEL BÍO BÍO  
FACULTAD DE CIENCIAS EMPRESARIALES  
DEPARTAMENTO DE CIENCIAS DE LA COMPUTACIÓN Y  
TECNOLOGÍAS DE LA INFORMACIÓN

**"ANÁLISIS DE DATOS EN  
PACIENTES POST  
ACV-ISQUÉMICO, USANDO  
TÉCNICAS CLÁSICAS DE  
MACHINE LEARNING"**

*AUTOR*

**ABRAHAM MARIANJEL SEPÚLVEDA**

**AÑO ACADÉMICO 2022**

**8 de enero de 2023**

**Profesora  
Guía**

**Dr. Carola Andrea Figueroa Flores**

Doctor en Informática con Mención Cum Loude

Dpto. Ciencias de la Computación y Tecnologías de la Información

Universidad del Bío Bío

**Profesor  
Co-Guía**

**Dr. Carlos Alonso Escudero Orozco**

Doctor en Ciencias Médicas

Dpto. Ciencias Básicas

Universidad del Bío Bío

**Comité  
Proyecto de  
Título**

**Mg. Marlene Elena Muñoz Sepúlveda**

Magíster en Informática Educativa

Dpto. Ciencias de la Computación y Tecnologías de la Información

Universidad del Bío Bío



UNIVERSIDAD DEL BÍO-BÍO  
FACULTAD DE CIENCIAS EMPRESARIALES

Este documento esta elaborado por el autor usando L<sup>A</sup>T<sub>E</sub>X.

El trabajo en este documento se llevo a cabo para obtener el título de Ingeniero Civil en Informática de la Universidad del Bío Bío, sede Chillán.

Copyright © 2023 por *Abraham Marianjel Sepúlveda*.

*"Nunca olvides que basta una persona o una idea para cambiar tu vida para siempre, ya sea  
para bien o para mal"*  
**J Brown**

# Agradecimientos

A Dios en primera instancia, que ha sido bueno conmigo durante toda mi vida, agradezco lo que hizo, lo que está haciendo y lo que hará en mí. Gracias por permitirme sonreír frente a todas las personas y adquirir virtudes de todas ellas, haciendo que crezca como ser humano y me expanda de distintas formas.

A mi profesora guía Carola Figueroa Flores, Doctora en Informática con Mención Cum Loude. Sus concejos, ideas fueron siempre útiles cuando mis soluciones a mis problemas se volvían confusas. Gracias por sus palabras de aliento, historias de experiencias vividas y sus orientaciones.

A mis profesores, quienes con sus conocimientos formaron al profesional que soy actualmente. Gracias por su paciencia, dedicación y tolerancia, haciendo una mención especial a mi Jefa de Carrera Marlene Muñoz Sepúlveda que estuvo siempre brindándome apoyo y concejo.

A mi madre, quien siempre me ha dado un amor inconmensurable, todo lo que podía dar y más y esperanza en todas las cosas que me esperan a futuro. Gozoso de tenerte como madre y que me acompañe en todos mis momentos. Gracias por ser quien eres y por creer en mí.

A mis amigos y compañeros, que dentro de esta maravillosa aventura dimos nuestro mejor esfuerzo para cumplir con todas las exigencias de la carrera y cooperando mutuamente para lograr el mejor resultado para todos. Especialmente, Diego Garrido y Daniel Gonzáles por su apoyo, constancia y amistad, que con ustedes la carrera fue menos pesada, más divertida y con una largo historial de aventuras que estuvieron en ella. Gracias por estar allí siempre.

# Resumen

**L**os Accidentes Cerebro Vascular, también llamados ACV o ictus, son de las principales causas de muerte en hombres y mujeres en Chile y el mundo. Los ACV podemos encontrarlos de dos tipos: ACV Isquémico por obstrucción de un vaso sanguíneo y ACV Hemorrágico por rotura de un vaso sanguíneo.

El proyecto utiliza una de las técnicas más conocidas de la Inteligencia Artificial (IA), como lo es el aprendizaje automático(Machine Learning) para realizar clasificaciones sobre pacientes que han sufrido un ACV y poder tomar decisiones prematuramente gracias a los modelos predictivos. La recopilación de datos de los pacientes fue una colaboración entre la investigadora e Informática Dra. Carola Figueroa con el médico e investigador Dr. Carlos Escudero que obtuvieron los datos del Hospital Herminda Martin de Chillán.

Se plantea la posibilidad de clasificar al paciente si tendrá un buen pronóstico cuando este dado de alta, por medio de la escala internacional de NIHSS(Escala de Accidentes Cerebrovasculares de los Institutos Nacionales de Salud), escala que mide el daño neurológico en los pacientes.

Como veremos a continuación, existen muchos tipos de algoritmos de Machine Learning, pero hay algunos que se repiten en el área de salud. Escogeremos 4 algoritmos y los desarrollaremos lo más simple posible, para que se pueden comparar con las mismas métricas y ningún algoritmo sufra una ventaja significativa sobre otro.

**Palabras Claves:** Accidente Cerebro Vascular, Machine Learning, Predicción

# Abstract

**C**erebro Vascular Accident, also called ACV or stroke, are one of the main causes of death in men and women in Chile and the world. CVA can be found in two types: Ischemic CVA due to obstruction of a blood vessel and Hemorrhagic CVA due to rupture of a blood vessel.

The project uses one of the best-known Artificial Intelligence (AI) techniques, such as Machine Learning, to classify patients who have suffered a stroke and to make premature decisions thanks to predictive models. The collection of patient data was a collaboration between the researcher and IT Dr. Carola Figueroa with the physician and researcher Dr. Carlos Escudero who obtained the data from the Herminda Martin de Chillán Hospital.

The possibility of classifying the patient if they will have a good prognosis when discharged is raised, using the NIHSS international scale (National Institutes of Health Stroke Scale), a scale that measures neurological damage in patients.

As we will see below, there are many types of Machine Learning algorithms, but there are some that are repeated in the health area. We will choose 4 algorithms and we will develop them as simple as possible, so that they can be compared with the same metrics and no algorithm suffers a significant advantage over another.

**Keywords:** Stroke, Machine Learning, Prediction

# Índice general

<b>AGRADECIMIENTOS</b>	<b>I</b>
<b>RESUMEN</b>	<b>II</b>
<b>ABSTRACT</b>	<b>III</b>
<b>1. INTRODUCCIÓN</b>	<b>1</b>
1.1. Descripción del Problema . . . . .	2
1.2. Descripción del proyecto . . . . .	4
1.2.1. Hipótesis . . . . .	4
1.2.2. Objetivo General . . . . .	4
1.2.3. Objetivos Específicos . . . . .	4
<b>2. MARCO TEÓRICO</b>	<b>6</b>
2.1. Inteligencia Artificial . . . . .	6
2.2. Machine Learning . . . . .	7
2.2.1. Machine Learning: Tipos de Aprendizajes . . . . .	9
2.2.2. Técnicas de Clasificación . . . . .	10
2.2.3. Decision Tree (Árbol de Decisión) . . . . .	10
2.2.4. Naïve Bayes (Redes de Bayes) . . . . .	12
2.2.5. Logistic Regression (Regresión Logística) . . . . .	14
2.2.6. Support Vector Machine (Máquina de Vectores de Soportes) .	15
2.2.7. Artificial Neural Networks (Redes Neuronales Artificiales) . .	15
2.2.8. Deep Belief Network (Red de creencias profundas) . . . . .	16
2.2.9. Feedforward Artificial Neural Network (Red Neuronal de Re- troalimentación) . . . . .	16

2.2.10. Recurrent Neural Networks (Redes Neuronales Recurrentes)	17
2.3. Deep Learning (Aprendizaje Profundo)	17
2.3.1. Entrenamiento de Redes Neuronales del Deep Learning	17
2.3.2. Convolutional Neural Networks (Redes Neuronales Convolucionales)	18
2.3.3. Neural Networks for Scarce Data Domains (Redes neuronales para dominios de datos escasos)	19
2.4. Dataset	20
2.5. Aspectos de la salud y la enfermedad	21
2.5.1. Accidente Cerebro Vascular	21
2.5.2. Accidente Cerebro Vascular Isquémico	21
2.5.3. Síntomas ACV Isquémico	22
2.5.4. Categorías de los ACV	22
2.5.5. Tratamiento y Actualizaciones en los ACV	23
<b>3. TRABAJOS RELACIONADOS</b>	<b>24</b>
<b>4. ESTUDIO EMPÍRICO</b>	<b>28</b>
4.1. Enfoque de la investigación	28
4.2. Metodología	29
4.3. Aplicación	31
4.4. Colección de datos de entrada	31
4.4.1. Diseño del instrumento	33
4.5. Preparación de los datos de entrada	34
4.5.1. Eliminación las filas de los pacientes que se expulsaron de la BDD	35
4.5.2. Variables significativas para la investigación	36
4.5.3. Descripción general de los datos	37
4.5.4. Missing data	40
4.5.5. Preprocesamiento de los datos y clasificación	42
4.5.6. Binary Encoding (Codificación binaria)	61
4.5.7. Label Encoding (Codificación de etiquetas)	63
4.5.8. One-Hot Encoding:	64



4.6.	Análisis de datos de entrada . . . . .	64
4.6.1.	Análisis de densidad y estimación por variable . . . . .	67
4.6.2.	Análisis por conteo de variables categóricas . . . . .	70
4.6.3.	Distibución de Diabetes e Hipertensión . . . . .	73
4.6.4.	Mapa de calor de variables . . . . .	76
4.7.	Naïve Bayes - Entrenamiento del algoritmo . . . . .	77
4.7.1.	Variable categórica . . . . .	78
4.7.2.	Creación del modelo y entrenamiento . . . . .	79
4.7.3.	Predicciones sobre los datos de prueba y métricas de rendimiento . . . . .	79
4.7.4.	Matriz de Confusión . . . . .	80
4.8.	Logistic Regression - Entrenamiento del algoritmo . . . . .	82
4.8.1.	Variable categórica . . . . .	82
4.8.2.	Creación del modelo y entrenamiento . . . . .	83
4.8.3.	Predicciones sobre los datos de prueba y métricas de rendimiento . . . . .	84
4.8.4.	Matriz de Confusión . . . . .	85
4.9.	Decision Tree - Entrenamiento del algoritmo . . . . .	86
4.9.1.	Variable categórica . . . . .	86
4.9.2.	Creación del modelo y entrenamiento . . . . .	87
4.9.3.	Predicciones sobre los datos de prueba y métricas de rendimiento . . . . .	89
4.9.4.	Matriz de Confusión . . . . .	90
4.10.	Random Forest - Entrenamiento del algoritmo . . . . .	91
4.10.1.	Variable categórica . . . . .	92
4.10.2.	Creación del modelo y entrenamiento . . . . .	93
4.10.3.	Predicciones sobre los datos de prueba y métricas de rendimiento . . . . .	94
4.10.4.	Matriz de Confusión . . . . .	95
<b>5.</b>	<b>RESULTADOS</b>	<b>97</b>
5.1.	Naïve Bayes - Testeo del algoritmo . . . . .	97

5.1.1. Predicciones sobre los datos del testing y métricas de rendimiento . . . . .	97
5.1.2. Matriz de Confusión . . . . .	98
5.2. Naïve Bayes - Uso del algoritmo . . . . .	99
5.2.1. Importancia de los predictores . . . . .	100
5.3. Logistic Regression - Testeo del algoritmo . . . . .	102
5.3.1. Predicciones sobre los datos del testing y métricas de rendimiento . . . . .	102
5.3.2. Matriz de Confusión . . . . .	103
5.4. Logistic Regression - Uso del algoritmo . . . . .	104
5.4.1. Importancia de los predictores . . . . .	104
5.5. Decision Tree - Testeo del algoritmo . . . . .	108
5.5.1. Predicciones sobre los datos del testing y métricas de rendimiento . . . . .	108
5.5.2. Matriz de Confusión . . . . .	109
5.6. Decision Tree - Uso del algoritmo . . . . .	110
5.6.1. Importancia de los predictores . . . . .	110
5.6.2. Importancia acumulada . . . . .	116
5.7. Random Forest - Testeo del algoritmo . . . . .	118
5.7.1. Predicciones sobre los datos del testing y métricas de rendimiento . . . . .	118
5.7.2. Matriz de Confusión . . . . .	119
5.7.3. Importancia de los predictores . . . . .	120
5.7.4. Importancia acumulada . . . . .	128
<b>6. DISCUSIONES, CONCLUSIONES Y RECOMENDACIONES</b>	<b>131</b>

# Índice de figuras

2.1. Diagrama de Venn con los subconjuntos de la IA . . . . .	8
2.2. Forma Gráfica de un Árbol de Desiciones . . . . .	11
2.3. Descripción del funcionamiento de una red neuronal convolucional (CNN) . . . . .	19
2.4. Diagrama de grafo ciclico de una red neuronal recurrente (RNN) . .	20
3.1. Resultados de la predicción de choque de accidentes . . . . .	27
4.1. Análisis de NIHSS estable o grave en la escala NIHSS inicial . . . . .	47
4.2. Análisis de NIHSS en la escala de Glasgow inicial . . . . .	49
4.3. Análisis de NIHSS en el Conteo de Globulos Blancos . . . . .	51
4.4. Análisis de NIHSS en el INR . . . . .	52
4.5. Análisis de NIHSS en los Trigliceridos . . . . .	54
4.6. Análisis de NIHSS en el Colesterol . . . . .	55
4.7. Análisis de NIHSS en la Glucosa . . . . .	57
4.8. Análisis de NIHSS en EDAD . . . . .	58
4.9. Análisis de NIHSS en la en la Diabetes . . . . .	60
4.10. Análisis de NIHSS en la Hipertensión . . . . .	61
4.11. Análisis de densidad de variables originales con escalas . . . . .	67
4.12. Análisis de densidad variables originales . . . . .	69
4.13. Análisis de densidad variables agregadas . . . . .	70
4.14. Análisis por conteo de variables categóricas . . . . .	72
4.15. Escala de Diabetes por escala de NIHSS alta ACV . . . . .	74
4.16. Distribución Hipertensión por escala NIHSS alta ACV . . . . .	75
4.17. Distribución de Hipertensión sobre Diabetes . . . . .	75
4.18. Mapa de calor de variables originales . . . . .	76

4.19. Mapa de calor de variables agregadas . . . . .	77
4.20. Matriz de confusión de entrenamiento Naive Bayes . . . . .	81
4.21. Matriz de confusión de entrenamiento Logistic Regression . . . . .	85
4.22. Árbol de decisión . . . . .	89
4.23. Matriz de confusión de entrenamiento Decision Tree . . . . .	91
4.24. Matriz de confusión de entrenamiento Random Forest . . . . .	96
5.1. Matriz de confusión de testing Naive Bayes . . . . .	99
5.2. Matriz de confusión de testing Logistic Regression . . . . .	103
5.3. Matriz de confusión de testing Decision Tree . . . . .	109
5.4. Importancia de los predictores en Decision Tree . . . . .	115
5.5. Importancia de los predictores acumulada en Decision Tree . . . . .	117
5.6. Matriz de confusión de testing Random Forest . . . . .	120
5.7. Importancia de los predictores en Random Forest . . . . .	127
5.8. Importancia de los predictores acumulada en Random Forest . . . . .	129

# Índice de tablas

4.1. Base de datos de pacientes post ACV Isquémico del Hospital Hermin- da Martin . . . . .	31
4.2. Eliminación de pacientes que no aportan en la investigación . . . . .	35
4.3. Dataset de variables para la investigación . . . . .	36
4.4. Missing data de variables . . . . .	40
4.5. Missing data finalizado . . . . .	42
4.6. Cantidad de pacientes en la escala NIHSS en alta . . . . .	43
4.7. Cantidad de pacientes en la clasificación NIHSS de alta . . . . .	44
4.8. Actualización del dataset incorporando variable NIHSS_alta_cat . . .	44
4.9. Clasificación binaria para la variable NIHSS_alta_:cat . . . . .	45
4.10. Actualización dataset con clsificación binaria . . . . .	45
4.11. Binary Encoding con las variables que actualmente poseen dos esta- dos activos . . . . .	62
4.12. Label Encoding con las variables que actualmente poseen alguna eti- queta . . . . .	63
4.13. One-Hot Encoding con las variables para clasificación . . . . .	64
4.14. Variables originales . . . . .	66
4.15. Variables agregadas por los métodos anteriores . . . . .	66
5.1. Predicciones probabilísticas para cada observación Bayes . . . . .	100
5.2. Predicciones probabilísticas con clasificación final Bayes . . . . .	101
5.3. Predicciones probabilísticas para cada observación Logistic Regression	105
5.4. Predicciones probabilísticas con clasificación final Logistic Regression	107
5.5. Predicciones probabilísticas para cada observación Decision Tree . .	111
5.6. Predicciones probabilísticas con clasificación final Decision Tree . . .	112

5.7. Importancia de los predictores Decision Tree . . . . .	113
5.8. Predicciones probabilísticas para cada observación Random Forest .	122
5.9. Predicciones probabilísticas con clasificación final Random Forest . .	124
5.10. Importancia de los predictores Random Forest . . . . .	125



# Capítulo 1

## INTRODUCCIÓN

**E**N nuestros tiempos los computadores o similares son indispensables para nuestro día a día, ayudando a mejorar la calidad de los trabajos y llevándolos a una mejor producción, siendo un gran impacto en la sociedad hoy más que nunca. Las múltiples ramas de las ciencias de la computación han ayudado al desarrollo progresista de otras áreas de trabajo e investigación, como lo es la medicina, economía, estadística o social, todo lo anterior mencionado se debe a la gran cantidad de bancos de memoria que puede procesarse y su rapidez, esto hace que las posibilidades de combinación sean altísimas entre las áreas.

Durante las últimas décadas se ha incrementado enormemente nuestra capacidad para recoger información en cualquier actividad, por ejemplo, en los negocios, recopilando información sobre procesos de producción, ventas, servicios, campañas de marketing, entre varios. La gran cantidad de información ha crecido el interés de las personas por utilizarlos para extraer la información que represente una ventaja competitiva para las organizaciones.

El campo interdisciplinario de la ciencia de la computación involucra métodos científicos, procesos y sistemas para extraer conocimiento o mejor entendimiento de datos en sus diferentes formas, ya sean información útil o no útil, idealmente estructurado. Dentro de las ciencias de la computación, existen especialidades que solucionan un problema específico, de las cuales nosotros nos enfocaremos en la



Inteligencia Artificial, que posee una variedad de metodologías para resolver los problemas de forma eficaz y eficiente.

Actualmente la Inteligencia Artificial se ha disparado en ascenso, ya que nos ayuda a resolver problemas con mucha certeza (aplicando bien el método) y es aplicable para un gran número de disciplinas de áreas de trabajo. El mercado se ha disparado con herramientas que utilizan aplicaciones con Inteligencia Artificial, en opciones comerciales, salud, social, etc.

Procesando los datos con Inteligencia Artificial llegamos a una de sus principales ramas y una de las más conocidas que es el Machine Learning, tomando un rol importantísimo en tareas con aprendizaje, análisis de datos, minería de datos, reconocimiento de patrones, entre varias. Todo lo anterior mencionado del Machine Learning, lo vuelve una de las ramas más atractivas para los sectores que trabajan grandes cantidades de datos.

Este trabajo se abordará una problemática referente al área de la salud, en una de las principales causas de muerte a nivel mundial y específicamente dentro de nuestra región es la segunda causa de muerte. La finalidad es analizar algunos factores que se producen al evaluar un Accidente Cerebro Vascular con Machine Learning.

### **1.1. Descripción del Problema**

Los ACV, hoy en día es una de las principales causas de muerte, asimismo las personas que logran sobrevivir quedan con secuelas o discapacidades en la mayoría de los casos, presentándose con más frecuencia sorpresivamente en los adultos jóvenes, pero también aumentando en los adultos mayores [1].

En Chile, los ACV son unos de las principales causas de muerte, solo el año 2021 hubieron 29.542 egresos hospitalarios por ACV siendo la segunda causa de

mortalidad a nivel país, después de las enfermedades isquémicas del corazón y no considerando la pandemia por el SARS-CoV-2. El registro de defunciones por ACV llego a los 7.501 casos ese mismo año, lo que equivale a 1 muerte cada 1 hora y 12 minuto [2].

La salud es vital para estimar nuestro bienestar y disminuir las posibles enfermedades en el menor plazo posible, vinculado a esto, el ACV posee una alta tasa de morbilidad, las muertes por esta enfermedad son muy rápidas en poco tiempo, una vez detectada por el ACV en sí o por las secuelas [3]. El impacto negativo de las secuelas en los pacientes es un alto costo sanitario, físico y social, encontrando en lo sanitario lo intrahospitalario como extra hospitalario, en lo físico la pérdida de la movilidad de una parte de su cuerpo (discapacidad) y en lo social, quizás la pérdida de un sentido (hablar o escuchar) o disminución de la calidad de vida de la persona. Ante lo anteriormente expuesto, la aparición de la enfermedad y su posible evolución se debería a los factores de riesgos para esta enfermedad [4].

En Ñuble, se cuenta con una red hospitalaria que lleva un registro de las enfermedades y pacientes que ingresan a los hospitales, de este modo se determinó que una de las principales causas de muerte en la región es consecuencia de los ACV, además una persona muerta al día y representa la primera causa en la zona y el país, hablando en términos de probabilidades. Esta enfermedad se trata de una urgencia, donde acceder a un tratamiento oportunamente, puede establecer la diferencia en el pronóstico de salud. Las acciones deben estar destinadas a preservar la integridad del tejido cerebral [5].

Para obtener resultados más óptimos, los médicos deben realizar una serie de exámenes para ayudar al pronóstico del paciente, ayudando a conservar la mayor parte de salud en la persona. Para una predicción médica con más apoyo, la IA y el Machine Learning ayuda a obtener resultados en el menor tiempo posible, lo que gracias a exámenes que se deben llevar a cabo. Es por esta razón que el rol de la IA jugará un papel importante a futuro en la salud, es así como esta disciplina está explorándose y ejecutándose en los países más desarrollados. Al mismo tiempo, los

errores de diagnósticos en los países en vías de desarrollo, las herramientas ligadas a la IA pueden cumplir con el rol de optimizar el diagnóstico de enfermedades y ayudar a la medicina preventiva [6].

## **1.2. Descripción del proyecto**

La presente sección tiene como propósito dar a conocer la hipótesis y los objetivos del proyecto.

### **1.2.1. Hipótesis**

Es posible determinar la técnica de Machine Learning más precisa, con el fin de clasificar según el tipo de secuela a los pacientes que han sufrido ACV Isquémico del Hospital Herminda Martín

### **1.2.2. Objetivo General**

Detectar la mejor técnica de Machine Learning para identificar los factores de mal pronóstico en adultos con diagnóstico de ACV Isquémico a través del análisis comparativo de su precisión para pacientes del Hospital Herminda Martín.

### **1.2.3. Objetivos Específicos**

1. Estudiar las distintas técnicas de Machine Learning que existen en la literatura.
2. Determinar qué técnicas de Machine Learning se van a comparar.
3. Elegir un mecanismo adecuado, para aplicar un modelo de Machine Learning al problema.

4. Implementar las técnicas seleccionadas de Machine Learning, para identificar la similitud entre las variables clínicas en los diferentes grupos y las variables que tienen mayor importancia en el pronóstico de los usuarios con diagnóstico ACV isquémico.
5. Realizar una comparación de las distintas técnicas de Machine Learning, en base a su precisión.

## Capítulo 2

# MARCO TEÓRICO

**E**L presente capítulo tiene como propósito presentar al lector algunas investigaciones y conceptos relacionados con IA, específicamente Machine Learning y en salud particularmente de ACV Isquémico, conceptos claves para esta investigación.

La organización del capítulo se encuentra de la siguiente manera, inicialmente, veremos Machine Learning y sus técnicas clásicas, pues consideramos estas podrían ser la respuesta a nuestra problemática junto a Deep Learning, posteriormente nos enfocaremos en algunos términos de salud que nos ayudaran a resolver y entender de mejor forma la raíz del problema.

### 2.1. Inteligencia Artificial

Las matemáticas nos han ayudado a interpretar y entender nuestro medio ambiente y poder ser capaz de predecir algunos sucesos en áreas como la cosmología o naturaleza o problemas incomprensidos por los humanos [7]. Hoy en día contamos con el área de las ciencias de la computación que fue creada hace solo un par de décadas atrás, siendo una de las ciencias más nuevas y que tiene gran valoración en la actualidad. En las ciencias de la computación podemos encontrar varias áreas aplicadas, de las cuales la Inteligencia Artificial es una de las más cotizadas, porque involucra en su relación la matemática con filosofía, biología, lingüística, entre

otras, pudiendo resolver los problemas con distintos tipos de algoritmos [7].

La IA llegó para resolver tareas que el ser humano realiza como tareas cotidianas básicas y complejas. Los algoritmos de IA, se basan en el aprendizaje automático, siendo que cada vez las máquinas pueden aprender por ellas mismas algunas cosas, es así que los humanos dejaremos de perder nuestro tiempo programando reglas para lidiar con muchas combinaciones de datos y situaciones que aparecen en nuestro mundo. Pues es así, que aprender los algoritmos, es fijarse como aprender desde pequeños, como el aprendizaje por refuerzos, que involucra una serie de técnicas de aprendizaje automático que las máquinas usan en sistemas artificiales [8].

En la IA, para que los modelos funcionen existen modelos neuronales y estos son los que determinan cómo se conectan los datos predictores con los objetivos a través de capas ocultas, y estas a su vez contienen unidades no observables [9]. Dentro de la Inteligencia Artificial, convive un sub conjunto llamada Machine Learning y su vez, dentro de Machine Learning vive un subconjunto llamado Deep Learning. Estos sub conjuntos interactúan con lo que es el Data Science y el Big Data, haciendo de las aplicaciones una variada gama de aplicaciones [10].

## 2.2. Machine Learning

Los problemas por computadora siempre son solucionado con un algoritmo que le indica a la maquina los pasos a seguir para dar solución a dicho problema, en un ejemplo clásico podemos usar un algoritmo de búsqueda, donde el dato a buscar seria la entrada y su salida seria la respuesta a que si se encontró o no y en cuanto tiempo, es bien conocido que para resolver el problema de búsqueda existen variados algoritmos, algunos más eficientes que otros, aplicables a un contexto u otro de mejor forma, solucionando el mismo problema.

Asimismo, existen tareas cotidianas como lo son la publicidad en el celular,




Figura 2.1: Diagrama de Venn con los subconjuntos de la IA

como muestra cosas que me gustan o que he estado pensando en comprar, esto es gracias a algoritmos de Machine Learning que captan la información de navegación de nuestro celular y nos muestra lo que nosotros estamos deseando o es de nuestro interés.

En el año 1959, Arthur Samuel, definió el concepto de Machine Learning como:

*“Un campo de estudio que le entrega a los computadores la habilidad de aprender sin haber sido explícitamente programado para eso”*

Tom M. Mitchell define el Machine Learning en uno de sus libros como:

*“El estudio de algoritmos de computación que mejoran automáticamente su rendimiento gracias a la experiencia. Se dice que un programa informático aprende sobre un conjunto de tareas, gracias a la experiencia y usando una medida de rendimiento, si su desempeño en estas tareas mejora con la experiencia”*

Es decir, estos algoritmos aprenden y mejoran solos gracias a la experiencias pasadas a diferencia de modelos que un experto puede asignar reglas y modela gracias a sus conocimientos.

El Machine Learning (ML) es el subconjunto de la Inteligencia Artificial, utilizándose para que las máquinas aprendan de grandes volúmenes de datos. Una vez adquirido el conocimiento, este puede ser empleado a otro conjunto de datos, recibiendo una atención cada vez mayor de un modelo que es capaz de interpretar los datos con mejor capacidad cada vez [11].

### 2.2.1. Machine Learning: Tipos de Aprendizajes

Para Machine Learning existen algunos enfoques para trabajar, los cuales son los más usados el aprendizaje supervisado y el aprendizaje no supervisado.

#### Aprendizaje Supervisado

Este enfoque es un método de análisis de datos que necesita de algoritmos que aprendan a través de entrenamiento, en el cual el programa es alimentado con datos etiquetados tanto con los atributos como la variable objetivo de cada iteración.

En el aprendizaje supervisado del algoritmo existen dos tareas comunes que son la clasificación y regresión. En las tareas de clasificación las variables objetivo, son valores etiquetados de manera nominal, mientras que en las tareas de regresión la variable objetivo tiene un dominio dentro de los números reales y por lo tanto pueden tomar infinitos valores [11].

#### Aprendizaje No Supervisado

El aprendizaje no supervisado tiene datos sin etiquetar que el algoritmo tiene que entender por si mismo, el propósito es descubrir patrones ocultos en ellos. Si nosotros le pedimos a nuestro programa *"predecir Y para nuestros datos A"* nosotros deberíamos *"pedirle que nos provea de la información de nuestros datos A"* [11].

Las tareas más comunes dentro del aprendizaje no supervisado son el *clustering*



y *dimensión reduction*, los cuales no son objeto de nuestro estudio por lo que sólo son mencionados en esta parte del documento.

### 2.2.2. Técnicas de Clasificación

Para que nuestro modelo de Machine Learning funcione, debemos categorizar los datos de entrada y salida, reconociendo atributos del elemento a clasificar y utilizando el conocimiento adquirido durante el entrenamiento del algoritmo para asignar un valor a la variable objetivo de dicho elemento.

La clasificación de datos es un proceso que posee dos etapas:

La *primera* es la etapa de aprendizaje, la cual los datos ingresan al modelo son entrenados con una serie de datos que sirven de base del algoritmo, logrando que se entrene con un set de entrenamiento que no son mas que tuplas de datos etiquetados tanto en sus atributos como en su variable objetivo.

La *segunda* etapa, el algoritmo ya ha sido entrenado con los datos de entrenamiento y esta listo para su clasificación de una variable cualquiera, siendo capaz de tomar algunos atributos de la variable, analizarlos y tomar una decisión basándose en los datos que fueron entregados anteriormente.

En la clasificación veremos algunas de las técnicas clásicas de Machine Learning, pertenecientes al enfoque de los algoritmos de aprendizaje supervisado, definiendo brevemente cada una de ellas [11].

### 2.2.3. Decision Tree (Árbol de Decisión)

Este algoritmo que se utiliza como herramienta de apoyo gráfico o modelo de decisiones con sus posibles consecuencias, también a veces son representados los costos y su posible utilidad (CART, Classification and Regression Trees). Este

método se crea particionando la entrada recursivamente en distintas ramas, siendo que la idea es crear un camino desde la raíz hasta las hojas, donde cada nodo podría ser una condición, así si se cumple la condición se sigue por el camino de decisión o por la otra rama si no se llegará a cumplir la condición [12].

La creación del modelo se puede representar con la siguiente ecuación:

$$f(x) = E[y|x] = \sum_{m=1}^M w_m I(x \in R_m) = \sum_{m=1}^M w_m \phi(x; v_m) \quad (2.1)$$

$R_m$  representa la región de  $m$ .

$w_m$  es respuesta media a esa región.

$v_m$  codifica la elección de la variable por la que dividir y el valor límite de la división.

La forma gráfica del modelo se puede representar de la siguiente forma en condiciones:




Figura 2.2: Forma Gráfica de un Árbol de Decisiones

Las condiciones se dan como alternativas de caminos a seguir.

### Usos para los Decision Tree

Al ser de fácil implementación, los Decision Tree son usados en diversas áreas, siendo las instituciones financieras las más comunes, ayudando a clasificar clientes, estableciendo sus riesgos o posibilidades financieras.

En el área de la salud son empleados para diagnósticos de infecciones a la sangre o predicción de ataque al corazón en pacientes de alto riesgo.

En el área de entretenimiento son ampliamente usados como métodos de seguimiento de movimiento y a su vez como método de reconocimiento facial.

### Ventajas y Desventajas

Principalmente las ventajas de esta técnica de Machine Learning es su bajo costo computacional y simple interpretación de resultados.

La mayor desventaja es que la técnica es propensa a caer en el sobreajuste, siendo a veces manipulada por quien lo implemente [13].

#### 2.2.4. Naïve Bayes (Redes de Bayes)

La clasificación de Naïve Bayes es un algoritmo probabilístico basados en la probabilidad condicional y teorema de Bayes con atributos fuertes y de independencia entre características [14]. Este modelo es de fácil construcción y funciona bien en comparación a los métodos más sofisticados de clasificación, lo que lo hace particularmente útil en los diferentes campos investigativos [15].

La fórmula condicional se expresa:

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{\left(\frac{\#casos\ favorables\ A \cap B}{\#casos\ posibles}\right)}{\left(\frac{\#casos\ favorables\ B}{\#casos\ posibles}\right)} \quad (2.2)$$

Desarrollando la ecuación nos queda:

$$P(A|B) = \frac{P(B|A) * P(A)}{P(B)} \quad (2.3)$$

Donde cada evento es tomado como:

$$P(A|B) = P(B_1|A) \times P(B_2|A) \times \dots \times P(B_n|A) \times P(A) \quad (2.4)$$

$P(A|B)$  es la probabilidad posterior de la clase (objetivo) dado el predictor (atributo).

$P(A)$  es la probabilidad previa de clase.

$P(B|A)$  es la probabilidad, que es la probabilidad de la clase dada del predictor.

$P(x)$  es la probabilidad previa del predictor.

Las Redes de Bayes se generan de reglas de decisión donde participan activamente las probabilidades que ocurren referente a eventos, siendo que en base a esas probabilidades y resultados obtenidos, se toman decisiones sobre cual arco de red moverse, al final del proceso, el resultado será dado por el valor del nodo final de la red.

### **Ventajas y Desventajas**

La gran sencillez para enfrentar problemas lo hace ser una de las técnicas clásicas de Machine Learning más fácil de interpretar al momento de los resultados, además debemos agregar al valor que son fáciles de construir y toma evidencia de muchos

atributos para realizar la predicción final.

### 2.2.5. Logistic Regression (Regresión Logística)

El algoritmo Logistic Regression modela la relación entre distintas variables utilizando una medida de error que se intentará minimizar en un proceso iterativo para poder realizar predicciones acertadas, llevando a cabo una clasificación binaria con una distribución Bernoulli en vez de Gaussian y después realiza una combinación lineal de las variables en un rango de 0 a 1 [16].

La ecuación lineal se debe ajustar:

$$y(X) = W^T X + \epsilon = \sum_{j=1}^D w_j x_j + \epsilon \quad (2.5)$$

$W^T X$  representa el producto escalar de entrada  $X$ .

$W$  e  $Y$  son vectores de pesos  $\in \{0, 1\}$ .

Ahora mostrando la distribución de Bernoulli:

$$p(y|x, w) = Ber(y|u(x)) \quad (2.6)$$

El resultado del intervalo quedaría  $0 \leq u(x) \leq 1$ .

El resultado de la ecuación nos ayudará a predecir valores con la mejor respuesta a partir del menor error posible, teniendo un valor continuo entre 0 y 1. Si existe un valor mayor o igual a 0.5, la clase será 1, en cambio si es menor será 0. Todo esto ocurre porque el algoritmo de Logistic Regression predice un valor en vez de una clase en función de las variables utilizadas.

### **Ventajas y Desventajas**

La Regresión Logística al igual que las técnicas anteriores es fácil de implementar, interpretar y muy eficiente al momento de entrenar, incluyendo que no hace suposiciones sobre distribuciones de clases en el espacio de características y es muy rápido para clasificar registros desconocidos.

Las principales desventajas de esta técnica radican en si el número de observaciones es menor que el número de características, no se debe utilizar la regresión logística; de lo contrario, puede provocar un sobreajuste y la difícil obtención de relaciones complejas. Además de los algoritmos más potentes y compactos, como lo son las redes neuronales, las cuales pueden superar fácilmente este algoritmo.

### **2.2.6. Support Vector Machine (Máquina de Vectores de Soportes)**

Si bien es cierto que los algoritmos para dar un resultado de aprendizaje automático deben ser capaces de aprender de su pasado y así poder predecir su futuro, de manera que las Support Vector Machine (SVM), están para ayudarnos a la regresión a base de un conjunto de muestras, donde existen dos valores generales, uno lo compone una matriz con variables explicativas de la muestra y el otro valor general está con el valor que se espera de la muestra. En este método, una función elige la predicción del valor esperado del caso mediante una entrada de datos [17].

### **2.2.7. Artificial Neural Networks (Redes Neuronales Artificiales)**

Aunque no será parte de las técnicas para analizar los datos, se considera importante para este trabajo poder mencionarla. La Artificial Neural Networks (ANN), se caracteriza por su aprendizaje supervisado y no supervisado, eso quiere decir que es un modelo que trabaja con ML en su forma base, aunque de igual forma se ocupa para DL, posee una arquitectura de procesadores múltiples interconectados [18]. Mediante la técnica señalada para el aprendizaje de una ANN, podemos guiarnos de dos formas de organizar las capas ocultas, las cuales son los perceptrones

multicapa (PMC) [19], encargado de las relaciones más complejas vía mayor coste de tiempo de entrenamiento, y la función de base radial (RBF) con una potencia de predicción reducida. De este modo, los métodos de aprendizaje que se emplean por lo regular son arquitecturas de redes neuronales tradicionales, donde solo se contienen dos o tres capas ocultas, imitando la operación que realiza el cerebro (Azath et al., 2020), en cambio, el Deep Learning aprenden sobre la marcha y su arquitectura puede llegar a tener 150 capas ocultas.

### **2.2.8. Deep Belief Network (Red de creencias profundas)**

Aunque no será parte de las técnicas para analizar los datos, importante conocer esta técnica. Esta red conlleva a un método de Machine Learning que nos ayuda con el rol probabilístico, que se ejecuta en los múltiples niveles de capas y variables ocultas, conectándose entre las capas visibles y ocultas, pero no en las capas visibles – visible u oculta – oculta [20].

### **2.2.9. Feedforward Artificial Neural Network (Red Neuronal de Retroalimentación)**

Aunque no será parte de las técnicas para analizar los datos, importante conocer esta técnica. Las Feedforward Artificial Neural Network (FANN) es la sucesora de ANN, trabajándose en diversos campos y aplicándose más a lo que es el Deep Learning. La diferencia de la FANN en contraste con su predecesora es su arquitectura con un conjunto de neuronas organizadas por capas y su algoritmo de entrenamiento que se ajusta a la muestra, ejecutando el proceso de aprendizaje que la hace crecer más [18].

### **2.2.10. Recurrent Neural Networks (Redes Neuronales Recurrentes)**

Aunque no será parte de las técnicas para analizar los datos, es importante que conozcamos esta técnica. Las Recurrent Neural Networks (RNN), son reconocidas por obtener información de datos secuenciales como lo son el procesamiento del lenguaje natural, videos y subtítulos de imágenes. Las RNN su modelo asigna parámetros únicos para representar a cada dato en una secuencia [21], para poder tener el control y no sufrir interrupciones sobre la secuencia. Su arquitectura es multicapa que comparte pasos entre los datos espaciados secuencialmente, para poder unir la información.

Su arquitectura se va incrementando con la conexión de nodos adyacentes a través de la adición de ciclos dentro de la red.

## **2.3. Deep Learning (Aprendizaje Profundo)**

Las técnicas de Machine Learning, están limitadas en el procesamiento de los datos naturales en forma cruda y para dar solución a la problemática se creó el aprendizaje profundo. La comprensión de la Inteligencia Artificial y como puede llegar a igual a los comportamientos humanos, inclusive en el aprendizaje, a veces superándonos, fue un gran acontecimiento que se debe a la gran contribución de Alan Turing [8]. El Deep Learning (DL) como subconjunto del Machine Learning entra en acción cuando los datos tienen demasiadas características, son enormes, se requiere de un nivel de precisión altísima y el ML no puede ofrecer completamente los resultados deseados.

### **2.3.1. Entrenamiento de Redes Neuronales del Deep Learning**

La forma para poder crear y entrenar los modelos de Deep Learning depende del método a implementar, para ello, al mismo tiempo, existen concepciones de



procesos similares que son para los modelos basados en este tipo de aprendizaje.

En primera instancia, se inicia con el entrenamiento desde cero, tomando un conjunto amplio de datos etiquetados, diseñando la red arquitectónica que aprenda [22], de igual modo se determina la transferencia de aprendizaje, donde implica el ajuste detallado de un modelo previamente que ya fue entrenado, como puede ser GoogleLeNet que es un sistema que está relacionado con el Deep Learning.

En segunda instancia, para trabajar con cantidades masivas de datos se requiere una extracción de características que será un enfoque más especializado, en vista de que las capas con sus tareas asignadas gozan de ciertas características de aprendizaje, estas características se pueden extraer en cualquier momento para darle mayor flexibilidad, clasificación y posible capacidad de regresión, como lo es el ejemplo de las máquinas de vectores de soporte (SVM) [23].

Por último, lo relacionado respecto al tiempo es fundamental, dado que los principales problemas que enfrenta la tecnología es el tiempo, siendo que hay algoritmos que quizás se pueden demorar hasta semanas con los datos. Para esto, el uso de recursos de cómputo mediante GPU, reduce el tiempo para entrenar una red y acota el tiempo de entrenamiento para resolver un problema, perfeccionando el modelo de Deep Learning [22].

### **2.3.2. Convolutional Neural Networks (Redes Neuronales Convolucionales)**

El Deep Learning ha demostrado muy buenos resultados para la resolución de problemas, en cambio, las limitaciones, sobre todo en el campo de la imagenología, ha hecho que se elabore un método diferente para que exista un análisis más preciso al momento de analizar la imagen. Este método se llama Convolutional Neural Networks (CNN), que tiene una arquitectura con mejor rendimiento para las tareas complejas relacionales [24].

Desde el año 2012, las arquitecturas basadas en CNN para visión artificial han crecido muchísimo; sin embargo, no todas han sido eficientes para ocuparse en tareas de visión artificial (Figueroa Flores, 2021), siendo el Grupo de Geometría Visual (VGG) de la Universidad de Oxford [25] una de las arquitecturas más utilizadas para las tareas de procesamiento de visión artificial.

Las CNN se forman usando tres tipos de capas, los cuales son las capas convolucionales, capas de pooling y capas totalmente conectadas.

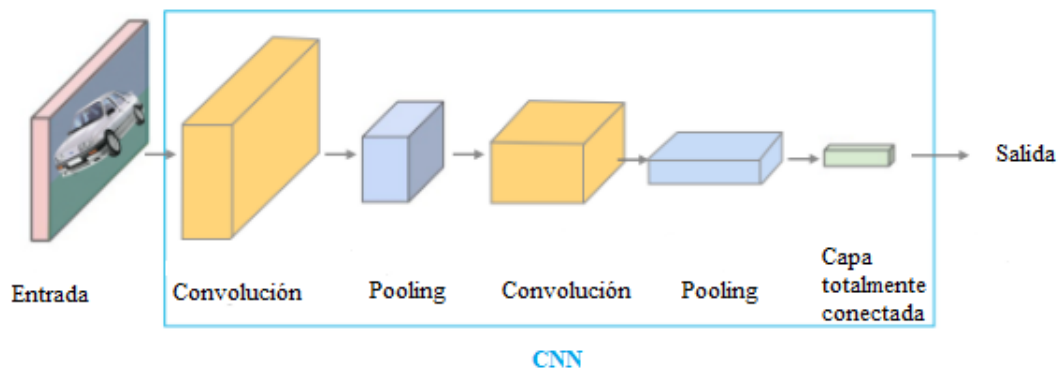


Figura 2.3: Descripción del funcionamiento de una red neuronal convolucional (CNN)

Para la CNN existen dos arquitecturas básicas de CNN, la cuales son CNN que entrega una salida para toda la imagen, como en la figura anterior y la Fully Convolutional networks que posee un codificador y decodificador, entrega una compresión de la información y su salida es por pixel. En las arquitecturas CNN existen varios ejemplos, como lo son AlexNet, entrenado con ImageNet, GoogLeNet donde posee 22 capas y sus neuronas son más complejas, entre otras [26].

### 2.3.3. Neural Networks for Scarce Data Domains (Redes neuronales para dominios de datos escasos)

En algunos casos, los modelos no contemplan con demasiados datos y por ende no se puede ser preciso con total certeza de la predicción de los resultados de la tarea. Por tanto, esto que se apunta a crear modelos que existan pocas muestras




Figura 2.4: Diagrama de grafo ciclico de una red neuronal recurrente (RNN)

etiquetadas disponibles [8]. Fei-Fei et al. [27] demostraron que es posible aprender nuevas categorías, una o pocas muestras por clase, aprovechando las categorías aprendidas anteriormente.

## 2.4. Dataset

Los Dataset están relacionados con el Big Data y con el procesamiento de datos, porque son datos tabulados, donde cada columna representa una variable y las filas datos, en consecuencia, el Dataset es una base de datos que se puede obtener de plataformas [28]. Los Datasets, nos ayudan a trabajar con volúmenes de datos más pequeños, ya que la principal función de los Datasets es que hacen referencia a una única base de datos de origen. Estos Datasets se clasifican según su origen y formato, que son utilizados según las necesidades de su modelo, existiendo tipos de archivo, carpeta, bases de datos y web, cada uno con su formato. Se pueden encontrar con grandes volúmenes de información con fuentes privadas como gratuitas, siendo una de ellas Google Dataset Search.

## **2.5. Aspectos de la salud y la enfermedad**

La salud es una de los aspectos más importantes en la vida, muchas veces nuestra salud se ve afectada por factores externos o internos a nuestra persona. “Este concepto involucra un estado completo de bienestar físico, mental y social, y no solamente la ausencia de afecciones o enfermedades” (World Health Organization, 1946). Estas palabras son relatadas en la conferencia del 46’ que hacen la referencia a que la persona no solo se compone de un estado físico, sino que hay más aspectos para sentirse saludable, ya que, si uno llegará a fallar, habría un déficit en la persona y poco a poco empezaría a carecer de un estado equilibrado que lo proporciona la salud.

### **2.5.1. Accidente Cerebro Vascular**

Un Accidente Cerebro Vascular es la detención del flujo de sangre a una parte del cerebro. En ocasiones se le llama como “Ataque Cerebral”, al igual, si el flujo sanguíneo se detiene por más de pocos segundos, el cerebro no recibirá nutrientes ni oxígeno, causando una muerte y un daño permanente en la zona afectada [29].

Existen dos tipos de ACV, los cuales son Isquémicos y Hemorrágicos.

### **2.5.2. Accidente Cerebro Vascular Isquémico**

Los isquémicos es el más común, generalmente, es causado por un coagulo sanguíneo (masas que se presentan cuando la sangre se endurece, pasando de líquida a sólida) que bloquea el vaso sanguíneo del cerebro, empezando a morir en cuestión de minutos las células cerebrales. Existen los ACV Isquémicos transitorios y los permanentes [29], diferenciándose en que los transitorios solo es cuando la sangre no llega al cerebro por unos instantes y el permanente es cuando ya tiene un tiempo prolongado el ACV, también conocido como Infarto Cerebral.

### 2.5.3. Síntomas ACV Isquémico

Los síntomas de un ACV Isquémico pueden ser:

- Entumecimiento o debilidad repentina de la cara, brazo o pierna (especialmente en un lado del cuerpo).
- Confusión repentina, dificultad para hablar o entender el lenguaje.
- Dificultad repentina para ver con uno o ambos ojos.
- Problemas para caminar repentino, mareos, pérdida de equilibrio o coordinación.
- Problemas para caminar repentino, mareos, pérdida de equilibrio o coordinación.

### 2.5.4. Categorías de los ACV

En los ACV para ayudar a optimizar el tratamiento específico, existen categorías que son identificadas por la escala de TOAST [30].

La primera categoría es la enfermedad Aterotrombótica aterosclerótica de gran vaso, se basa en la reducción de tejido sanguíneo medio o grande en el cerebro, con ubicación cortical o subcortical, con localización vertebrobasilar o carotídea, donde se encuentra presente una aterosclerosis u obstrucción con estenosis u oclusión de las arterias craneales. También la aterosclerosis sin estenosis con menos factores de riesgo se puede encontrar presente en esta categoría. La segunda categoría es el Cardioembolismo, es una reducción de tejido sanguíneo medio o grande, de localización cortical, en la que existe una cardiopatía embolígena [31]. La tercera categoría es la enfermedad oclusiva de pequeño vaso infarto lacunar, es una reducción de tejido sanguíneo de tamaño pequeño, en el sector de una arteria de perforante cerebral puede provocar una oclusión en el transporte de nutrientes. La cuarta categoría se debe a otras causas, siendo que son un tamaño o una localización variable que además no están en las tres categorías anteriores, por ello, se pueden producir enfermedades metabólicas, alteraciones de la coagulación, displacia

fibromuscular, etc. La quinta categoría hace énfasis a los orígenes desconocidos con estudios incompletos o completos, por más de una etiología [32].

### **2.5.5. Tratamiento y Actualizaciones en los ACV**

Para los accidentes cerebro vasculares, los factores que pueden influir son muchísimos y hay algunos que influye hasta los fumadores afectando al sistema nervioso central [33].

Las ayudas diagnósticas, nos proveen información sobre el grado de lesión y la identificación de la lesión [34] como las imágenes. La recomendación es que la vía aérea y con asistencia ventilatoria en pacientes con ACV, siendo que se deberían lograr saturaciones de oxígeno mayores al 94 %, también la temperatura >38 grados Celsius y agregando a todo la anterior se debe monitorizar la hiperglucemia, porque si perdura por más de 24 hrs se asocia a un peor desenlace [29].

## Capítulo 3

### TRABAJOS RELACIONADOS

**E**L análisis del estado del Arte contempla una revisión bibliográfica, contextualizando los avances en la investigación acerca de la Inteligencia Artificial y el área de salud. Se agrupará en dos tipos: la primera es sobre programas o métodos de prevención de Accidentes Cerebros Vasculares y la segunda sobre las investigaciones que se han realizado, considerando diferentes variables del problema con Machine Learning.

Los avances en los hospitales en los países desarrollados han permitido la implementación de la IA en sus sistemas, pero con esto nacen nuevos desafíos [35], Google es uno de los partidarios en algoritmos con IA que aprenda a partir de la experiencia desde 0 a partir del Machine Learning, pero en la actualidad el problema es procesar grandes volúmenes de información o a veces los datos pueden estar incompletos debido a la incompatibilidad de los sistemas en que se registran, también la presión de entregar una investigación o producto sin prolijidad y beneficio real para las personas.

Con el aumento de las tecnologías en el campo médico y avance de las técnicas de Machine Learning, se ha desarrollado un interés por el mundo científico para predecir algún proceso anticipado o secuela después de un ACV. Investigadores en el 2019 [36], realizaron estudio utilizando Random Forest, Redes Neuronales y Regresión Logística para la predicción de pronóstico de un paciente de ACV Isquémico tres meses después del evento inicial. Los autores deseaban predecir la

mortalidad a los 3 años luego de salir de la rehabilitación con un algoritmo basado en Árboles de decisión. El mejor modelo fue Random Forest con la implementación del minority oversampling technique, el cual logró un AUC de 0.928 [37]. Yu et al. [38] usaron técnicas de Machine Learning considerando el Árbol de Decisión, siendo el objetivo clasificar la severidad del Accidente Cerebro Vascular Isquémico. El árbol se construyó con 13 variables de 18 propuestas y los datos usados son los del National Institutes of Health Stroke Scale con personas mayores a 65 años. Con esta técnica se logró tener un accuracy del 91.11 %. prediciendo el nivel de discapacidad, si poseía discapacidad o no, la información recogida de las primeras 24 horas en el hospital luego de 90 días [39]. Los predictores incluían información de exámenes de escáner, demografía e información clínica de los pacientes.

Con la herramienta de las imágenes nace la posibilidad de generar algoritmos para un método más actualizado de la detección de esta enfermedad y futura prevención, ya que existen variadas técnicas [34] como la RM con DWI para la evaluación de presencia y extensión de isquemia posterior y la CTA y DSA para la trombosis de la arteria. Siguiendo con la investigación en imágenes en un estudio en Estados Unidos [29] se analizaron 610.000 casos y 185.000 son recurrentes en el 2019, además los signos y síntomas producen lesiones visibles para la imagenología, se pudo llegar a que el manejo médico y prevención secundaria es vital para que el proceso sea exitoso. Tomando en cuenta los beneficios y riesgos para tomar un tipo de terapia específica y oportuna, es importante educar a la comunidad para reconocer algunos síntomas del ACV y así poder acudir al centro médico más cercano. Finalmente, esta enfermedad llegará a ser un 6,2 % para los países desarrollados, con estos datos mencionados es importante crear un algoritmo para la atención basado en experiencias internacionales como nacionales [29] y es igual de importante crear un modelo que nos permita predecir esas secuelas o futuros problemas en el tratamiento para llevar a cabo una prevención exitosa evitando la recurrencia.

En los diseños la IA puede generar estudios de Aprendizaje Profundo como, estudio de revisión sistemática del diseño, estándares de informes y afirmaciones



de los estudios de aprendizaje profundo [22], el objetivo siempre es que el modelo con el Aprendizaje Profundo sea efectivo y eficaz, pero se debe ayudar con médicos expertos, ellos evalúan los diagnósticos mediante imágenes y contrastan los resultados obtenidos con los de la IA, teniendo en cuenta que esta investigación cuenta con una gran fuente de datos como Ensayos controlados, datos Medline y ensayos que la Organización Mundial de la Salud poseía desde el 2010 hasta el 2019, en ellos se encontraron registros aleatorios de aprendizaje profundo con bajo nivel de sesgo. En síntesis, la información que es emitida por los modelos de aprendizaje profundo, de igual forma es manipulada por los expertos, que este caso son los médicos, ya que los algoritmos [35] son experimentales y aunque son pioneros, no pueden dejar en total confianza al algoritmo para que determine un diagnóstico más certero.

Las redes de datos convolucionales demostraron en Corea que el uso de ellas es una herramienta que predice con precisión los cuidados intensivos en servicios médicos (Kang et al., 2020), asumiendo que el modelo predictivo, basado en Deep Learning, es superior a las otras herramientas de predicción y puntuaciones convencionales [40]. Cabe destacar, que el algoritmo de aprendizaje es muy eficiente por la cantidad de capas que puede poseer el modelo, puesto que entre más capas mayor puede ser el aprendizaje. Pese a las evidencias que demuestran de la efectividad y el desempeño del modelo, pueda ser mejor al del humano, existe un miedo por la implementación en los sistemas de salud, lo que puede provocar que el crecimiento del Deep Learning, perezca de una base amplia para su desarrollo [35].

En el área de la implementación de un modelo con CNN, encontramos el trabajo de Chunjiao Dong , Chunfu Shao,<sup>1,2</sup> Juan Li, and Zhihua Xiong del 2018, que desarrolla específicamente la predicción sobre los accidentes de tránsito [41]. Ellos demuestran una técnica novedosa con un modelo de regresión multivariable, que presenta la relación entre lo examinado y los accidentes de tránsito. Como resultados el módulo identifica las variables de entrada y representaciones de características de salida, aunque se haya reducido su magnitud, se conserva la información original. Además, el modelo propuesto explica mejor los problemas de heterogeneidad en predicción de accidentes de tráfico y puede ser aplicado a casos

similares.

TABLE 6: Results of roadway segment crash count prediction.

	Major injury	Minor injury	No injury	Total
Observation mean	0.096	0.556	1.306	1.986
Proposed model				
Estimated mean	0.110	0.573	1.335	2.019
MAE	0.030	0.080	0.071	0.150
RMSD (%)	17.298	29.961	27.206	43.652
Deep learning model without the regression layer				
Estimated mean	0.101	0.556	1.332	1.989
MAE	0.043	0.202	0.405	0.520
RMSD (%)	20.620	51.741	65.086	82.862
SVM model				
Estimated mean	0.101	0.513	1.329	1.943
MAE	0.055	0.257	0.471	0.660
RMSD (%)	26.022	61.350	72.416	96.636

Figura 3.1: Resultados de la predicción de choque de accidentes

En este caso el modelo propuesto en contraste con el SVM en la categoría choque con daños menores es significativo (29.961 % versus 61.350 %), así es como la predicción medida por el RMSD se puede mejorar un 84,58 % y un 158,27 % en comparación con el modelo de aprendizaje profundo sin la capa de regresión y el modelo SVM.

## Capítulo 4

# ESTUDIO EMPÍRICO

**E**N la era de la información, la mayoría de las organizaciones están aprovechando la capacidad de la IA para lograr ventajas competitivas, es por eso por lo que la ciencia de datos que resulta difícil notar el camino para llegar allí. Así, la forma de tener éxito con proyectos orientados a ciencia de datos es utilizar el ciclo de vida y las metodologías adecuadas. El Marco de Procesos OSEMN comprende el flujo de trabajo del proyecto y garantiza que todos en el equipo estén en la misma página y no distraídos [42].

El presente capítulo tiene como finalidad el análisis de la documentación del trabajo realizado y la implementación del método utilizado. Para lograr un resultado óptimo primero se define que método se siguió. En la sección posterior se implementará los pasos comunes para los algoritmos, puesto que estos pasos serán frecuentes en los algoritmos que se utilizarán. Al finalizar, se presentarán nuevas secciones con los nombres de los algoritmos y los pasos no comunes del método dentro de estos.

### 4.1. Enfoque de la investigación

La investigación cuenta con un enfoque cuantitativo por los resultados que se quieren llegar a obtener, donde primará el análisis matemático de la base de datos y entre los algoritmos a comparar. El tipo de investigación será de carácter ex-

perimental, ya que medirá tendencias en los resultados arrojados por los algoritmos.

La población será todas las personas que salen registradas en la base de datos a trabajar. En este caso específico, son los pacientes post Ataque Cerebrovascular Isquémico del Hospital Herminda Martin de Chillán. La muestra serán los pacientes post Ataque Cerebro Vascular Isquémico registrados en la base de datos y que cumplan con algunos criterios médicos para su análisis.

### 4.2. Metodología

El diseño metodológico dará una guía con los pasos a seguir a grande escala para la obtención de la finalización del proyecto. Se tendrá en cuenta el tipo, el enfoque, la población y la muestra para iniciar el trabajo. Siguiendo con estrategia, utilizaremos el libro de *Machine Learning in Action* [13], utilizando el procedimiento de la sección “*Steps in developing a machine learning application*” que consta de 6 pasos para la implementación de una aplicación que utiliza técnicas de Machine Learning.

1. **Colección de los datos de entrada:** El primer paso para implementar una aplicación que trabaje utilizando técnicas de Machine Learning es coleccionar los datos que serán analizados, hay muchas formas en las que se pueden obtener grandes cantidades de datos a través de internet y de manera local, este paso se refiere a esas opciones y al esfuerzo aplicado para obtener dichos datos pudiendo ahorrar algo de tiempo y esfuerzo en adquirir datos públicos.
2. **Preparación de datos de entrada:** Una vez que ya se obtienen los datos, es necesario asegurarse que estén en el formato correcto para ser procesados por el algoritmo de Machine Learning seleccionado. El formato que usaremos en este estudio es la lista de Python El beneficio de tener este formato estándar es que puede mezclar, combinar algoritmos y fuentes de datos. Es posible que deba hacer algún formato específico del algoritmo aquí.

Por lo que este paso involucra, si fuera necesario, formatear los datos para adaptarlos a la necesidad de cada algoritmo.

3. **Analizar los datos de entrada:** Este podría ser tan simple como mirar los datos que ha analizado en un editor de texto para hacer Asegúrese de que los pasos 1 y 2 realmente funcionen y no tenga un montón de valores vacíos. También puede mirar los datos para ver si puede reconocer algún patrón o si hay algo obvio, como algunos puntos de datos que son muy diferentes del resto del conjunto. Si se trabaja con un sistema de producción o se sabe como se deben ver los datos o se confía en la fuente, este paso se puede omitir
4. **Entrenamiento del algoritmo:** Aquí es donde tiene lugar el aprendizaje automático. Este paso y el siguiente paso es donde se encuentran los algoritmos "básicos", según el algoritmo. Alimentas el algoritmo con buenos datos limpios de los primeros dos pasos y extraer conocimiento o información. Este conocimiento que a menudo almacena en un formato eso es fácilmente utilizable por una máquina para los siguientes dos pasos.
5. **Testeo del algoritmo (Pruebe el algoritmo):** Aquí es donde la información aprendida por el algoritmo es testeada, es decir, se mide el nivel de acierto que tiene nuestro algoritmo, utilizando los datos de entrenamiento podremos establecer el grado de eficacia de nuestra implementación de la técnica seleccionada, si los resultados no son los esperados es probable que haya que volver a etapas previas para intentar identificar el error, que tal vez sea en los datos de entrada o en el algoritmo en sí, y tratar de solucionarlo. Una vez realizado los cambios hará falta volver a pasar por todos los pasos anteriores una vez más.
6. **Uso del algoritmo:** Una vez se han consumado todos los pasos, no queda más que usar el algoritmo, esta etapa implica tener que volver a ejecutar los pasos 1, 2, 3 y 5.

Sabemos que el proceso de programación podemos desarrollarlo óptimamente en los lenguajes más usados para el Machine Learning que son Java, R o Python. Par este proyecto se escogió Python por su simpleza y múltiple documentación para el desarrollo de las técnicas de Machine Learning.

### 4.3. Aplicación

Para empezar, debemos implementar los pasos sugeridos en la sección 4.1 en el mismo orden que se nos presenta. Los pasos 1, 2 y 3 son comunes para todos los algoritmos, por ende, solo se mostrará una vez en la presente investigación. Al finalizar esta sección se verán los pasos 4, 5 y 6 en cada Algoritmo presentado.

### 4.4. Colección de datos de entrada

Para empezar, debemos implementar los pasos sugeridos en la sección 4.1 en el mismo orden que se nos presenta. Los pasos 1, 2 y 3 son comunes para todos los algoritmos, por ende, solo se mostrará una vez en la presente investigación. Al finalizar esta sección se verán los pasos 4, 5 y 6 en cada Algoritmo presentado.

```
[1]: # Libreria para la manipulación de los datos
import pandas as pd
import numpy as np

# Leer el dataframe
dataframe = pd.read_excel('../bdd/bdd_final.xlsx')
print(dataframe)
```

CLAVE	COMUNA	TELEFONOS	EDAD	...	IL-6 corregida	log IL-6	IL-6/VEGF	IL-6/PIGF
1	san carlos		53	...	0,156952708	-0,804	-0,454839548	-0,825732298
2	coihueco	41723921-74822219	54	...	0,012817828	-1,892	-0,882899371	-1,081411325
3	chillan	71818219-50323843	78	...	0,436365262	-0,360	-0,230735564	-0,296817468
.	.	.	.	...	.	.	.	.
.	.	.	.	...	.	.	.	.
.	.	.	.	...	.	.	.	.
75	pinto	82525308	79	...	0,842328176	-0,075	-0,047317636	-0,08950326
76	chillan	50711724-87107760	54	...	1,273106319	0,105	0,054145766	0,137865611
TENS	chillan	85226191-96473857	69	...	0,795830574	-0,099	#iNUM!	#iNUM!

Tabla 4.1: Base de datos de pacientes post ACV Isquémico del Hospital Herminda Martin

```
[2]: # Mostramos las variables que posee la base de datos
columns_names = dataframe.columns.values
print(columns_names)
```

```
['CLAVE' 'COMUNA' 'TELEFONOS' 'FICHA CLINICA' 'CTA CTE'
↪ 'EDAD' 'PESO'
'TALLA' 'HTA' 'DIABETES' 'OTRAS PATOLOGIAS' 'FUMA' 'FC'
↪ 'PAS' 'PAD'
'GLUCOSA' 'Hb A/C %' 'COL. TOTAL' 'TRIGLICERIDOS' 'LDL'
↪ 'HDL' 'HCTO'
'HB' 'VCM' 'HCM' 'VHS' 'PLAQUETAS' 'INR' 'CONTEO G.B.' 'P.C.
↪ R'
'Nitrogeno Ureico' 'Uremia' 'Creatinina' 'TTPA' 'TP' 'NA'
↪ 'K' 'CL'
'Fosfatasa Alcalina' 'Gamma glutamil' 'Transaminasa
↪ piruvica'
'Trans oxal' 'AREA DE LESION' 'No ESTENOSIS INTRACRANEAL'
'No ESTENOSIS EXTRACRANEAL' '% ESTENOSIS INTRACRANEAL'
'% ESTENOSIS EXTRACRANEAL' 'GLASGOW AL INICO ACV' 'NIHSS
↪ INICO ACV'
'RANKIN INICIO ACV' 'NIHSS alta ACV' 'RANKIN alta ACV'
↪ 'NIHSS 6M'
'RANKIN 6M' 'diag Elopez' 'DIAG. NEUROLOGICO' 'Diag2'
↪ 'Diag3'
'FECHA TOMA MUESTRA' 'Estado paciente' 'Fecha defuncion'
'CAUSA DEFUNCION' 'MOTIVO DE DESCARTE' 'TROMBOLISIS'
↪ 'eduardo'
'sirve' 'escala' 'exosomes 1' 'exosomes 2' 'VEGF ab1'
↪ 'VEGF ab2'
'VEGF prome' 'plgf mg prot' 'plgf mg prot.1' 'plgf
↪ promedio' 'logVEGF'
'logPlGF' 'logPCR' 'PCR/VEGF ratio' 'PCR/PLGF ratio' 'IL-6
↪ (pg/ml)'
'IL-6 corregida' 'log IL-6' 'IL-6/VEGF' 'IL-6/PlGF']
```

Mostramos la cantidad de pacientes y variables(columnas) que posee la BDD:

```
[3]: print('Existen {} pacientes con {} variables.'.
      ↪format(*dataframe.shape))
print("Existen", dataframe.size, "elementos")
```

Existen 75 pacientes con 85 variables.

Existen 6375 elementos

Se observa que la BDD posee muchas variables y pocos pacientes registrados en las tuplas. Esto hará que sea más difícil la predicción para los algoritmos, así que necesitamos un nuevo instrumento.

#### 4.4.1. Diseño del instrumento

Desde el punto de vista científico, para que un estudio salga lo más certero posible necesitamos variables significativas para la investigación y con la menor pérdida de datos posible. En la BDD todas las variables presentan importancia, algunas son imprescindibles para la investigación, otras con pocos datos completados o simplemente las variables sujetas a interpretación médica (humana). Debido a lo anterior se seleccionaron las variables por dos motivos, el primero fue porque eran las que estaban más completas en la BDD y el segundo porque se determinó que eran más significativas para la investigación por estudios realizados al ACV y dataset presentes en internet. A continuación, se mostrarán las variables escogidas y una pequeña descripción de ellas.

**HTA:** "si" o "no", HIPERTENSIÓN

**DIABETES:** "si" o "no"

**EDAD:** Edad del paciente

**GLUCOSA:** Nivel de azúcar en la sangre

**COL. TOTAL:** Cantidad de Colesterol en la sangre

**TRIGLICERIDOS:** Cantidad de trigliceridos en la sangre



**INR:** Índice internacional normalizado (INR, por sus siglas en inglés) es un tipo de cálculo que se basa en los resultados de las pruebas de tiempo de protrombina

**CONTEO G.B.:** Conteo de globulos blancos en la sangre

**GLASGOW AL INICO ACV:** Escala de 15 puntos medica que es para medir el estado de conciencia. Esta pertenece a la Inicial

**NIHSS INICO ACV:** Escala de 42 puntos más empleada para la valoración de funciones neurológicas básicas en la fase aguda del ictus isquémico, tanto al inicio como durante su evolución. Esta pertenece a la Inicial

**NIHSS alta ACV:** Pertenece cuando es dado de alta el paciente

La Hipertensión Arterial y la Diabetes son factores de riesgo altos en cualquier enfermedad no trasmisible, por esto son de las primeras seleccionadas, que además contaremos con las escalas de Glasgow y Nihss que son escalas internacionales para la evaluación del ACV Isquémico.

### 4.5. Preparación de los datos de entrada

El segundo paso descrito en la metodología corresponde a la parte más larga de la elaboración para la preparación de la utilización de un modelo de Machine Learning, debido a que este paso todos los datos serán usados como entrada del algoritmo. Aquí se llevará a cabo una identificación y corrección de los puntos de datos faltantes/anomalías según sea necesario.

### 4.5.1. Eliminación las filas de los pacientes que se expulsaron de la BDD

Como se indicó anteriormente, se dispone de 75 tuplas con 85 columnas, con un total de 6375 elementos, que se planean disminuir por indicación del médico que facilitó la base de datos. La indicación fue que había pacientes que fueron retirados del programa y estaban marcados con un “out” en la variable de “diag Elopez”.

```
[4]: dataframe.drop(dataframe[(dataframe['diag Elopez'] == 'out')].index, inplace=True)

# mostramos 10 columnas
pd.options.display.max_columns = 10

# Mostramos las primeras 7 tuplas
dataframe.head(7)
```

CLAVE	COMUNA	TELEFONOS	EDAD	...	IL-6 corregida	log IL-6	IL-6/VEGF	IL-6/PIGF
1	san carlos		53	...	0,156952708	-0,804	-0,454839548	-0,825732298
2	coihueco	41723921-74822219	54	...	0,012817828	-1,892	-0,882899371	-1,081411325
3	chillan	71818219-50323843	78	...	0,436365262	-0,360	-0,230735564	-0,296817468
.	.	.	.	...	.	.	.	.
.	.	.	.	...	.	.	.	.
.	.	.	.	...	.	.	.	.
75	pinto	82525308	79	...	0,842328176	-0,075	-0,047317636	-0,08950326
76	chillan	50711724-87107760	54	...	1,273106319	0,105	0,054145766	0,137865611
TENS	chillan	85226191-96473857	69	...	0,795830574	-0,099	#iNUM!	#iNUM!

Tabla 4.2: Eliminación de pacientes que no aportan en la investigación

```
[5]: print('Existen {} pacientes con {} variables.'.
        format(*dataframe.shape))

print("Existen", dataframe.size, "elementos")
```

Existen 46 pacientes con 85 variables.

Existen 3910 elementos

### 4.5.2. Variables significativas para la investigación

Ahora asignamos las variables significativas, para esto se extrae la información del marco de trabajo, identificando las variables categóricas para un arreglo completamente nuevo y así empezar a trabajar sobre el nuevo archivo.

```
[6]: # Tomaremos las variables más significativas para la
      ↪ investigación

columnasMuestra = ['HTA', 'DIABETES', 'EDAD', 'GLUCOSA',
      ↪ 'COL. TOTAL', 'TRIGLICERIDOS', 'INR', 'CONTEO G.B.',
      ↪ 'GLASGOW AL INICO ACV', 'NIHSS INICO ACV', 'NIHSS alta
      ↪ ACV']

dataset = dataframe[*columnasMuestra]

# Mostramos las columnas que se ajusten a la cantidad de
      ↪ espacio

pd.options.display.max_columns = 0

dataset.head(5)
```

HTA	DIABETES	EDAD	GLUCOSA	COL. TOTAL	TRIGLICERIDOS	INR	CONTEO G.B.	GLASGOW AL INICO ACV	NIHSS INICO ACV	NIHSS alta ACV
		53	137,09	268	130	1,08	41,9	11	14	42
si	si	54		187	130		8,3	15	6	0
si	si	78	359,42	159	97	0,89	8,5	15	5	2
.	.	.	.	.	.	.	.	.	.	.
.	.	.	.	.	.	.	.	.	.	.
si	si	79	116,99	109	118		9,9		2	2
si	si	54	211,58			0,99	6,5	15	1	1
si	si	69	217,21	202	232	1,03	10,4	0		

Tabla 4.3: Dataset de variables para la investigación

Mostramos la cantidad de pacientes y variables(columnas) que posee la BDD después de la selección de variables significativas para la investigación:

```
[7]: print('Existen {} pacientes con {} variables.'.
      ↪ format(*dataset.shape))

print("Existen", dataset.size, "elementos")
```

Existen 46 pacientes con 11 variables.

Existen 506 elementos

### 4.5.3. Descripción general de los datos

En la descripción de los datos, se muestran parámetros, pérdida de datos (Missing Data), forma y su descripción estadística.

```
[8]: # Check Dataset:
def check_data(dataset, head=5):
    print(20*"-" + "Información".center(20) + 20*"-" )
    print(dataset.info())
    print(20*"-" + "Forma de datos".center(20) + 20*"-" )
    print(dataset.shape)
    print("\n" + 20*"-" + "Los primeros 5 datos".center(20) +
    ↪+ 20*"-" )
    print(dataset.head())
    print("\n" + 20 * "-" + "Los últimos 5 datos".
    ↪center(20) + 20 * "-")
    print(dataset.tail())
    print("\n" + 20 * "-" + "Missing Data".center(20) + 20_
    ↪* "-")
    print(dataset.isnull().sum())
    print("\n" + 20 * "-" + "Describir los datos".
    ↪center(20) + 20 * "-")
    print(dataset.describe().T)
check_data(dataset)
```

```
----- Información -----
<class 'pandas.core.frame.DataFrame'>
Int64Index: 46 entries, 0 to 74
Data columns (total 11 columns):
#   Column                Non-Null Count  Dtype
---  -
0   HTA                    42 non-null    object
1   DIABETES                34 non-null    object
2   EDAD                   44 non-null    float64
```

```

3    GLUCOSA                38 non-null    float64
4    COL. TOTAL             40 non-null    float64
5    TRIGLICERIDOS          40 non-null    float64
6    INR                    37 non-null    float64
7    CONTEO G.B.            46 non-null    float64
8    GLASGOW AL INICO ACV    29 non-null    float64
9    NIHSS INICO ACV         39 non-null    float64
10   NIHSS alta ACV          32 non-null    float64

```

dtypes: float64(9), object(2)

memory usage: 4.3+ KB

None

```

----- Forma de datos -----
(46, 11)

```

```

-----Los primeros 5 datos-----

```

	HTA	DIABETES	...	NIHSS INICO ACV	NIHSS alta ACV
0	NaN	NaN	...	14.0	42.0
1	si	si	...	6.0	0.0
2	si	si	...	5.0	2.0
3	si	si	...	1.0	0.0
4	si	si	...	3.0	2.0

[5 rows x 11 columns]

```

-----Los últimos 5 datos -----

```

	HTA	DIABETES	...	NIHSS INICO ACV	NIHSS alta ACV
68	si	no	...	NaN	NaN
69	no	no	...	2.0	0.0
72	si	si	...	2.0	2.0
73	si	si	...	1.0	1.0
74	si	si	...	NaN	NaN

## CAPÍTULO 4. ESTUDIO EMPÍRICO

---

[5 rows x 11 columns]

```
----- Missing Data -----
HTA                4
DIABETES           12
EDAD               2
GLUCOSA            8
COL. TOTAL         6
TRIGLICERIDOS      6
INR                9
CONTEO G.B.        0
GLASGOW AL INICO ACV  17
NIHSS INICO ACV     7
NIHSS alta ACV     14
dtype: int64
```

```
-----Describir los datos -----
count      mean  ...      75%  _
↳max
EDAD        44.0   71.522727  ...   80.5000  90.
↳00
GLUCOSA     38.0  135.529211  ...  162.5925  359.
↳42
COL. TOTAL  40.0  162.750000  ...  188.5000  342.
↳00
TRIGLICERIDOS  40.0  123.450000  ...  142.0000  232.
↳00
INR         37.0    1.197568  ...    1.2000    3.
↳08
CONTEO G.B.  46.0   10.119783  ...   10.3750   41.
↳90
```

```
GLASGOW AL INICO ACV    29.0    13.482759    ...    15.0000    15.
↪00
NIHSS INICO ACV         39.0     5.564103    ...     6.5000    21.
↪00
NIHSS alta ACV          32.0     5.687500    ...     4.0000    42.
↪00
```

```
[9 rows x 8 columns]
```

La descripción de los datos nos ayuda a evaluar los casos particulares de las variables que serán tratadas en los siguientes títulos.

#### 4.5.4. Missing data

Los datos que faltan ocurren cuando no se almacena ningún valor en la variable de observación. Aunque el Missing data es una ocurrencia muy común, estos pueden tener una presión significativa en los resultados de la aplicación del instrumento. Para corregir este problema, existen variadas técnicas estadísticas, siendo una de ellas la mediana y el redondeo como lo muestra [43] en algunas variables que utilizaremos para llenar las celdas faltantes. Tomaremos la información que mostramos anteriormente.

```
[9]: dataset.isnull().sum()
```

	MISSING DATA
HTA	4
DIABETES	12
EDAD	2
GLUCOSA	8
COL. TOTAL	6
TRIGLICERIDOS	6
INR	9
CONTEO G.B.	0
GLASGOW AL INICO ACV	17
NIHSS INICO ACV	7
NIHSS alta ACV	14

Tabla 4.4: Missing data de variables

Como se demuestra en la tabla 4.4, casi todas las variables hay missing data, así

que el algoritmo para trabajar será el siguiente:

```
[10]: valores_por_defecto = {  
    'HTA': "DESCONOCIDO",  
    'DIABETES' : "DESCONOCIDO",  
    'EDAD':dataset["EDAD"].median().  
↪round(),  
    'GLUCOSA':dataset["GLUCOSA"].  
↪median(),  
    'COL. TOTAL':dataset["COL. TOTAL"].  
↪median(),  
    'TRIGLICERIDOS':  
↪dataset["TRIGLICERIDOS"].median(),  
    'INR':dataset["INR"].median(),  
    'GLASGOW AL INICO ACV':  
↪dataset["GLASGOW AL INICO ACV"].median().round(),  
    'NIHSS INICO ACV':dataset["NIHSS_↪  
↪INICO ACV"].median().round(),  
    'NIHSS alta ACV':dataset["NIHSS alta_↪  
↪ACV"].median().round(),  
    }  
  
# Missing Data  
dataset = dataset.fillna(value=valores_por_defecto)
```

Comprobamos si ahora existe missing data:

```
[11]: dataset.isnull().sum()
```



	MISSING DATA
HTA	0
DIABETES	0
EDAD	0
GLUCOSA	0
COL. TOTAL	0
TRIGLICERIDOS	0
INR	0
CONTEO G.B.	0
GLASGOW AL INICO ACV	0
NIHSS INICO ACV	0
NIHSS alta ACV	0

Tabla 4.5: Missing data finalizado

Como se ve en la tabla 4.5, ya no existe missing data.

#### 4.5.5. Preprocesamiento de los datos y clasificación

La preparación de los datos para el modelo de aprendizaje automático es lo que nos llevará a decidir qué modelo podremos ocupar, ya que trabajar para modelos de clasificación no es lo mismo que para los de regresión. Los pasos exactos para la preparación de los datos dependerán del modelo utilizado y de los datos recopilados, pero requerirá cierta cantidad de manipulación de datos para cualquier aplicación de aprendizaje automático.

##### Análisis de variable Objetivo

La NIHSS es la escala más utilizada para evaluar la función neurológica básica durante la fase aguda del ictus isquémico, tanto en su inicio como en su evolución. Consta de 11 ítem que te permiten explorar rápidamente [44]. Según las puntuaciones obtenidas, podemos dividir la gravedad neurológica en varios grupos: 0: sin déficit; 1: déficit mínimo; 2-5: leve; 6-15: moderado; 15-20: déficit importante; >20: Gravemente. La puntuación global inicial tiene buen valor de pronóstico [30], dado que  $\text{NIHSS} \leq 6$  corresponde a una excelente recuperación neurológica y que cada aumento de punto empeora la evolución. Para los pacientes con fibrilación auricular, se ha considerado que un  $\text{NIHSS} \geq 16$  tiene un pronóstico muy precario [45]. Otra ventaja de esta escala es que puede predecir la respuesta a la terapia trombolítica y estimar la gravedad en función de la puntuación.

La variable más importante que nos interesa tener en la predicción, es la escala Nihss de alta, esto para poder tener un aseguramiento de la predicción del estado de salud del total de pacientes a través del camino de salida del hospital, es decir, conoceremos el estado del paciente al salir de alta y según las demás variables existe una tendencia para la predicción en la escala del alta.

```
[12]: dataset["NIHSS alta ACV"].value_counts()
```

NIHSS alta ACV	Cantidad
1	19
0	12
2	6
42	2
4	2
8	1
10	1
18	1
32	1
5	1

Tabla 4.6: Cantidad de pacientes en la escala NIHSS en alta

En esta escala los valores menores son los que nos ayudan a tener un mejor pronóstico para los pacientes, es por eso que se decide crear una variable con los resultados que da el test NIHSS.

**Crear columna para NIHSS\_alta\_cat** Esta columna nos servirá para clasificación de los estados de la variable Nihss.

```
[13]: # Realizamos la clasificación de la escala
condicionesALTA = [
    (dataset['NIHSS alta ACV'] == 0),
    (dataset['NIHSS alta ACV'] == 1),
    (dataset['NIHSS alta ACV'] >= 2) & (dataset['NIHSS alta_
↵ACV'] <= 5),
    (dataset['NIHSS alta ACV'] >= 6) & (dataset['NIHSS alta_
↵ACV'] <= 15),
```

```

    (dataset['NIHSS alta ACV'] >= 16) & (dataset['NIHSS_
↪alta ACV'] <= 20),

    (dataset['NIHSS alta ACV'] > 20),
]
valoresALTA = ["Sin Déficit", "Déficit Mínimo", "Leve_
↪(Trombolisando)", "Moderado (Buen Pronostico)", "Déficit_
↪Importante", "Grave"]
dataset['NIHSS_alta_cat'] = np.select(condicionesALTA, _
↪valoresALTA)
dataset['NIHSS_alta_cat'].value_counts()

```

NIHSS_alta_cat	Cantidad
<b>Déficit Mínimo</b>	19
<b>Sin Déficit</b>	12
<b>Leve (Trombolisando)</b>	9
<b>Grave</b>	3
<b>Moderado (Buen Pronostico)</b>	2
<b>Déficit Importante</b>	1

Tabla 4.7: Cantidad de pacientes en la clasificación NIHSS de alta

```

[14]: # Como son muchas columnas, muestro menos columnas
pd.options.display.max_columns = 6

dataset.head(5)

```

	HTA	DIABETES	EDAD	GLUCOSA	...	NIHSS INICO ACV	NIHSS alta ACV	NIHSS_alta_cat
0	DESCONOCIDO	DESCONOCIDO	53	137,09	...	14	42	Grave
1	si	si	54	119,995	...	6	0	Sin Déficit
2	si	si	78	359,42	...	5	2	Leve (Trombolisando)
.	.	.	.	.	...	.	.	.
.	.	.	.	.	...	.	.	.
.	.	.	.	.	...	.	.	.
72	si	si	79	116,99	...	2	2	Leve (Trombolisando)
73	si	si	54	211,58	...	1	1	Déficit Mínimo
74	si	si	69	217,21	...	4	1	Déficit Mínimo

Tabla 4.8: Actualización del dataset incorporando variable NIHSS\_alta\_cat

**Crear columna para NIHSS\_alta\_ESTABLE\_O\_GRAVE** Esta columna nos ayudará a observar si el paciente esta estable o crítico. Nos interesa saber el pronóstico

del paciente, por eso es necesaria una variable binaria sobre el alta del paciente. Luego de obtener la nueva columna, se comparará con las otras variables.

```
[15]: dataset['NIHSS_alta_ESTABLE_O_GRAVE'] = np.
      ↪where(dataframe['NIHSS alta ACV'] <=6, 0, 1)

dataset['NIHSS_alta_ESTABLE_O_GRAVE'].value_counts()
```

NIHSS_alta_ESTABLE_O_GRAVE	Cantidad
0	26
1	20

Tabla 4.9: Clasificación binaria para la variable NIHSS\_alta\_cat

Se demuestra en la tabla 4.10 que si en la escala de Nihss el paciente se encuentra con un valor leve o sin déficit obtendrá el valor 0 binario, al contrario todos los demás obtendrán el valor 1.

```
[16]: dataset.head(5)
```

	HTA	DIABETES	EDAD	...	NIHSS alta ACV	NIHSS_alta_cat	NIHSS_alta_ESTABLE_O_GRAVE
0	DESCONOCIDO	DESCONOCIDO	53	...	42	Grave	1
1	si	si	54	...	0	Sin Déficit	0
2	si	si	78	...	2	Leve (Trombolizando)	0
.	.	.	.	.	.	.	.
.	.	.	.	...	.	.	.
.	.	.	.	.	.	.	.
72	si	si	79	...	2	Leve (Trombolizando)	0
73	si	si	54	...	1	Déficit Mínimo	0
74	si	si	69	...	1	Déficit Mínimo	1

Tabla 4.10: Actualización dataset con clasificación binaria

### Análisis de las escalas de INICIO del ACV

**NIHSS INICO ACV** Esta variable la transformaremos a la categoría que nos ofrece la literatura con sus 6 estados.

```
[17]: # Análisis NIHSS INICO ACV
print(f'NIHSS INICO ACV Variable min: {dataset["NIHSS INICO_
      ↪ACV"].min()}')
```

```
print(f'NIHSS INICO ACV Variable max: {dataset["NIHSS INICO_
↪ACV"].max()}')
print(f'NIHSS INICO ACV Variable: {dataset["NIHSS INICO_
↪ACV"].nunique()}')
```

NIHSS INICO ACV Variable min: 0.0

NIHSS INICO ACV Variable max: 21.0

NIHSS INICO ACV Variable: 14

```
[18]: # Realizamos la clasificación de la escala
condicionesINICIO = [
    (dataset['NIHSS INICO ACV'] == 0),
    (dataset['NIHSS INICO ACV'] == 1),
    (dataset['NIHSS INICO ACV'] >= 2) & (dataset['NIHSS_
↪INICO ACV'] <= 5),
    (dataset['NIHSS INICO ACV'] >= 6) & (dataset['NIHSS_
↪INICO ACV'] <= 15),
    (dataset['NIHSS INICO ACV'] >= 16) & (dataset['NIHSS_
↪INICO ACV'] <= 20),
    (dataset['NIHSS INICO ACV'] > 20),
]
valoresINICIO = ["Sin Déficit", "Déficit Mínimo", "Leve_
↪(Trombolisando)", "Moderado (Buen Pronostico)", "Déficit_
↪Importante", "Grave"]
dataset['NIHSS_INICIO_cat'] = np.select(condicionesINICIO,
↪valoresINICIO)
dataset['NIHSS_INICIO_cat'].value_counts()
```

```
[18]: Leve (Trombolisando)          28
      Moderado (Buen Pronostico)    12
      Déficit Mínimo                3
      Grave                        1
      Déficit Importante            1
```

```
Sin Déficit                                1  
Name: NIHSS_INICIO_cat, dtype: int64
```

```
[19]: # Para gráficos matplotlib  
import matplotlib.pyplot as plt  
%matplotlib inline  
import seaborn as sns  
from matplotlib import style  
  
sns.catplot(y="NIHSS_INICIO_cat",  
            hue="NIHSS_alta_ESTABLE_O_GRAVE", kind="count",  
            palette="Set1", edgecolor=".9",  
            data=dataset);
```




Figura 4.1: Análisis de NIHSS estable o grave en la escala NIHSS inicial

La realización de la escala fue acorde a los mismos parámetros que la variable objetivo, solo que en este caso dejamos de lado la variable binaria.

Se observa en el gráfico 4.1 que el valor mínimo que llegó un paciente fue de 0 encontrándose Sin Déficit neurológico y el máximo con 21 puntos con un Déficit importante, además se aprecia gracias al gráfico que los pronósticos moderado y leve son los que más abundan en la muestra, al mismo se demuestra que esos pacientes al salir de alta en su mayoría tienen un buen pronóstico según la escala de NIHSS.

**GLASGOW AL INICO ACV** La escala de Glasgow se divide en tres grupos puntuables de manera independiente que evalúan la apertura de ojos sobre 4 puntos, la respuesta verbal sobre 5 y la motora sobre 6, siendo la puntuación máxima y normal 15 y la mínima 3 (The status of the Glasgow Coma Scale). Se considera traumatismo craneoencefálico leve al que presenta un Glasgow de 15 a 13 puntos, moderado de 12 a 9 y grave menor o igual a 8 (Cien escalas de interés en Neurología. Prous Science, 2001). A continuación procesaremos la escala.

```
[20]: # Análisis GLASGOW AL INICO ACV
print(f'GLASGOW AL INICO ACV Variable min:_{
    ↪{dataset["GLASGOW AL INICO ACV"].min()}_')
print(f'GLASGOW AL INICO ACV Variable max:_{
    ↪{dataset["GLASGOW AL INICO ACV"].max()}_')
print(f'GLASGOW AL INICO ACV Variable: {dataset["GLASGOW AL_{
    ↪INICO ACV"].unique()}_')
```

```
GLASGOW AL INICO ACV Variable min: 0.0
```

```
GLASGOW AL INICO ACV Variable max: 15.0
```

```
GLASGOW AL INICO ACV Variable: 7
```

```
[21]: # Realizamos la clasificación de la escala
dataset['GLASGOW_cat'] = pd.cut(dataset['GLASGOW AL INICO_{
    ↪ACV'], bins=[-1, 8, 12, 15], labels=['Grave', 'Moderado',_{
    ↪'Leve'}])
dataset['GLASGOW_cat'].unique()
```

```
[21]: ['Moderado', 'Leve', 'Grave']  
Categories (3, object): ['Grave' < 'Moderado' < 'Leve']
```

```
[22]: sns.catplot(y="GLASGOW_cat",  
    hue="NIHSS_alta_ESTABLE_O_GRAVE", kind="count",  
    palette="Set1", edgecolor=".9",  
    data=dataset);
```




Figura 4.2: Análisis de NIHSS en la escala de Glasgow inicial

Se observa en el gráfico 4.2 que el valor mínimo que llegó un paciente fue de 0 encontrándose grave neurológico y el máximo con 15 puntos encontrándose leve, además se aprecia gracias al gráfico que el pronóstico Leve es el que abunda en esta variable, al mismo se demuestra que esos pacientes al salir de alta en su mayoría tienen un buen pronóstico según la escala de NIHSS.



**Análisis de otras variables de médicas**

Las siguientes clasificaciones están sacadas de Medline Plus [46], que es una páginas que poseen escalas para la clasificación de las variables que veremos.

**Conteo de Glóbulos Blancos** Los glóbulos blancos son parte del sistema inmunológico del cuerpo y ayudan a combatir infecciones y otras enfermedades. Los registraremos en 3 categorías.

```
[23]: # Análisis CONTEO G.B.
print(f'CONTEO G.B. Variable min: {dataset["CONTEO G.B."].
      ↪min()}')
print(f'CONTEO G.B. Variable max: {dataset["CONTEO G.B."].
      ↪max()}')
print(f'CONTEO G.B. Variable: {dataset["CONTEO G.B."].
      ↪nunique()}')
```

CONTEO G.B. Variable min: 3.76

CONTEO G.B. Variable max: 41.9

CONTEO G.B. Variable: 38

```
[24]: # Realizamos la clasificación de la escala
dataset['CONTEO G.B._cat'] = pd.cut(dataset['CONTEO G.B.'],
      ↪bins=[0, 4.5, 10, 1000], labels=['Bajo', 'Normal', 'Alto'])
dataset['CONTEO G.B._cat'].unique()
```

```
[24]: ['Alto', 'Normal', 'Bajo']
```

```
Categories (3, object): ['Bajo' < 'Normal' < 'Alto']
```

```
[25]: sns.catplot(y="CONTEO G.B._cat",
      ↪hue="NIHSS_alta_ESTABLE_O_GRAVE", kind="count",
      palette="Set2", edgecolor=".9",
      data=dataset);
```




Figura 4.3: Análisis de NIHSS en el Conteo de Globulos Blancos

Se observa en el gráfico 4.3 que la mayoría de los pacientes están en la categoría normal y ellos tienen en más del 50 % un buen pronóstico.

**INR** El INR sirve para ver la coagulación de la sangre, siendo que esta examen ayuda a saber qué tipo de medicamentos podemos administrar o averiguar la causa de los coágulos sanguíneos anormales.

```
[26]: # Análisis INR
print(f'INR Variable min: {dataset["INR"].min()}')
print(f'INR Variable max: {dataset["INR"].max()}')
print(f'INR Variable: {dataset["INR"].nunique()}')
```

```
INR Variable min: 0.89
```

```
INR Variable max: 3.08
```

```
INR Variable: 26
```

```
[27]: dataset['INR_cat'] = pd.cut(dataset['INR'], bins=[0.0, 2, 4, 1000], labels=['Riesgo', 'Normal', 'No Anticoagula'])
dataset['INR_cat'].unique()
```

```
[27]: ['Riesgo', 'Normal']
Categories (3, object): ['Riesgo' < 'Normal' < 'No Anticoagula']
```

```
[28]: sns.catplot(y="INR_cat", hue="NIHSS_alta_ESTABLE_O_GRAVE", kind="count",
                  palette="Set2", edgecolor=".9", data=dataset);
```

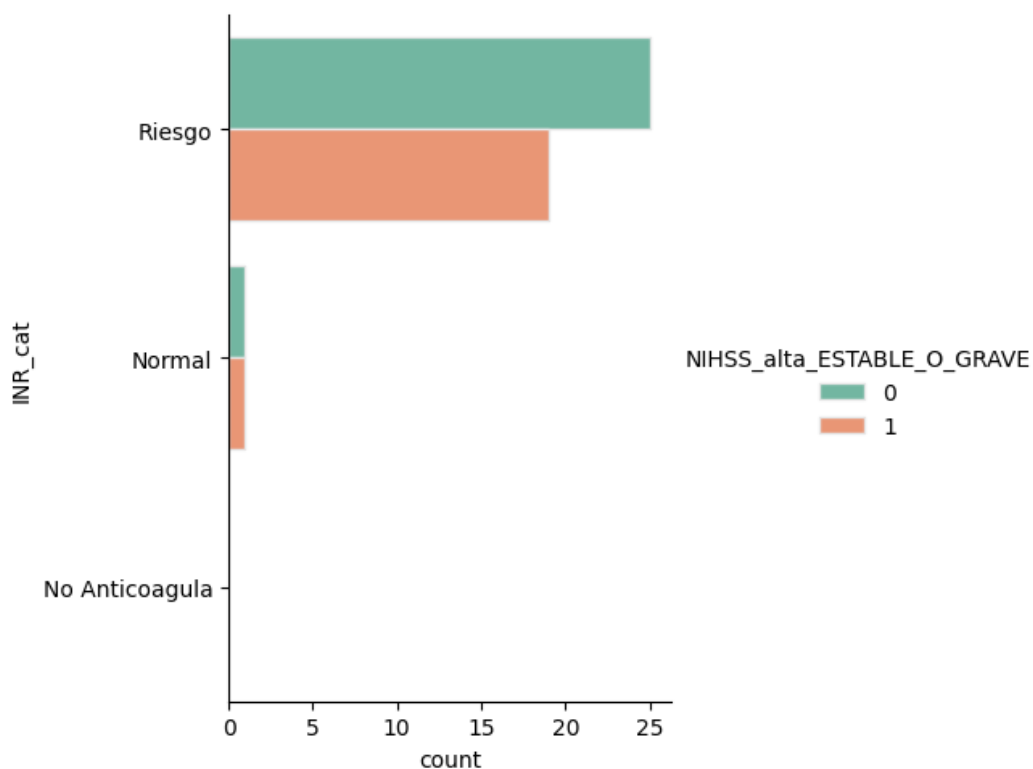


Figura 4.4: Análisis de NIHSS en el INR

Se observa en el gráfico 4.4 que la mayoría de los pacientes están en la categoría de Riesgo, aunque un grupo importante tiene un pronóstico favorable. En la categoría Normal no se sabe si el paciente obtuvo un buen o mal pronóstico.

**Triglicéridos** Los triglicéridos son el principal tipo de grasa que se transporta en la sangre para obtener energía o se almacena en las células del cuerpo según las necesidades energéticas entre comidas.

```
[29]: # Análisis TRIGLICERIDOS
print(f'TRIGLICERIDOS Variable min:_{
    ↪{dataset["TRIGLICERIDOS"].min()}_')
print(f'TRIGLICERIDOS Variable max:_{
    ↪{dataset["TRIGLICERIDOS"].max()}_')
print(f'TRIGLICERIDOS Variable: {dataset["TRIGLICERIDOS"].
    ↪nunique()}_')
```

TRIGLICERIDOS Variable min: 57.0

TRIGLICERIDOS Variable max: 232.0

TRIGLICERIDOS Variable: 31

```
[30]: dataset['TRIGLICERIDOS_cat'] = pd.
    ↪cut(dataset['TRIGLICERIDOS'], bins=[0, 150, 200, 500, _
    ↪10000], labels=['Normal', 'Límite alto', 'Alto', 'Muy_
    ↪Alto'])
dataset['TRIGLICERIDOS_cat'].unique()
```

```
[30]: ['Normal', 'Límite alto', 'Alto']
```

```
Categories (4, object): ['Normal' < 'Límite alto' < 'Alto' _
    ↪< 'Muy Alto']
```

```
[31]: sns.catplot(y="TRIGLICERIDOS_cat", _
    ↪hue="NIHSS_alta_ESTABLE_O_GRAVE", kind="count",
    ↪palette="Set2", edgecolor=".9",
    ↪data=dataset);
```




Figura 4.5: Análisis de NIHSS en los Trigliceridos

El gráfico 5.2 muestra que la mayoría de los pacientes están en la categoría Normal, aunque un grupo importante tiene un pronóstico favorable. En la categoría Alta un gran porcentaje tiene un mal pronóstico con el alta del ACV.

**Colesterol Total** El colesterol es una grasa natural que se encuentra en todas las células del cuerpo y es necesaria para que el cuerpo funcione correctamente. El colesterol se produce en el hígado en su mayoría, aunque también se puede obtener de algunos alimentos.

```
[32]: # Análisis COL. TOTAL
print(f'COL. TOTAL Variable min: {dataset["COL. TOTAL"].
      ↪min()}')
print(f'COL. TOTAL Variable max: {dataset["COL. TOTAL"].
      ↪max()}')
print(f'COL. TOTAL Variable: {dataset["COL. TOTAL"].
      ↪nunique()}')
```

COL. TOTAL Variable min: 85.0

COL. TOTAL Variable max: 342.0

COL. TOTAL Variable: 34

```
[33]: dataset['COL. TOTAL_cat'] = pd.cut(dataset['COL. TOTAL'],
    ↪bins=[0, 150, 400, 1000, 100000], labels=['Normal',
    ↪'Límite alto', 'Alto', 'Muy Alto'])
dataset['COL. TOTAL_cat'].unique()
```

```
[33]: ['Límite alto', 'Normal']
Categories (4, object): ['Normal' < 'Límite alto' < 'Alto'
    ↪< 'Muy Alto']
```

```
[34]: sns.catplot(y="COL. TOTAL_cat",
    ↪hue="NIHSS_alta_ESTABLE_O_GRAVE", kind="count",
    palette="Set2", edgecolor=".9",
    data=dataset);
```




Figura 4.6: Análisis de NIHSS en el Colesterol

El gráfico 4.6 muestra que la mayoría de los pacientes están en la categoría Limite alto, siendo que un grupo importante tiene un pronóstico favorable.

**Glucosa** El azúcar en la sangre, es llamada “glucosa”, siendo el azúcar principal en la sangre. Proviene de los alimentos que consume y es la principal fuente de energía. Su sangre transporta glucosa a cada célula de su cuerpo para obtener energía.

```
[35]: # Análisis EDAD
print(f'GLUCOSA Variable min: {dataset["GLUCOSA"].min()}')
print(f'GLUCOSA Variable max: {dataset["GLUCOSA"].max()}')
print(f'GLUCOSA Variable: {dataset["GLUCOSA"].nunique()}')
```

```
GLUCOSA Variable min: 82.61
```

```
GLUCOSA Variable max: 359.42
```

```
GLUCOSA Variable: 39
```

```
[36]: dataset['GLUCOSA_cat'] = pd.cut(dataset['GLUCOSA'],
    ↪bins=[0, 90, 160, 230, 3000], labels=['Bajo', 'Normal',
    ↪'Alto', 'Muy Alto'])
dataset['GLUCOSA_cat'].unique()
```

```
[36]: ['Normal', 'Muy Alto', 'Alto', 'Bajo']
Categories (4, object): ['Bajo' < 'Normal' < 'Alto' < 'Muy
    ↪Alto']
```

```
[37]: sns.catplot(y="GLUCOSA_cat",
    ↪hue="NIHSS_alta_ESTABLE_O_GRAVE", kind="count",
    palette="Set2", edgecolor=".9",
    data=dataset);
```




Figura 4.7: Análisis de NIHSS en la Glucosa

El gráfico 4.3 muestra que la mayoría de los pacientes están en la categoría Normal, aunque un grupo importante tiene un pronóstico poco favorable en el alta. En la categoría Alta un gran porcentaje importante tiene un buen pronóstico con el alta del ACV.

**Edad** La edad juega un rol importante para determinar el estado que se puede encontrar el cuerpo para responder a una enfermedad o tratamiento, es por eso que una de las variables que si o si debe estar presente.

```
[38]: # Análisis EDAD
print(f'EDAD Variable min: {dataset["EDAD"].min()}')
print(f'EDAD Variable max: {dataset["EDAD"].max()}')
print(f'EDAD Variable: {dataset["EDAD"].nunique()}')
```

```
EDAD Variable min: 38.0
```

```
EDAD Variable max: 90.0
```

```
EDAD Variable: 28
```



```
[39]: dataset['EDAD_cat'] = pd.cut(dataset['EDAD'], bins=[0, 13,
↳18, 45, 60, 100], labels=['Niño', 'Adolecente', 'Adulto_
↳Joven', 'Adulto', 'Anciano'])
dataset['EDAD_cat'].unique()
```

```
[39]: ['Adulto', 'Anciano', 'Adulto Joven']
Categories (5, object): ['Niño' < 'Adolecente' < 'Adulto_
↳Joven' < 'Adulto' <
'Anciano']
```

```
[40]: sns.catplot(y="EDAD_cat", hue="NIHSS_alta_ESTABLE_O_GRAVE",
↳kind="count",
palette="Set2", edgecolor=".9",
data=dataset);
```




Figura 4.8: Análisis de NIHSS en EDAD

El gráfico ?? muestra que la mayoría de los pacientes que son ancianos pasaron

por el ACV, aunque un grupo mayoritario de esa categoría tiene un pronóstico favorable en el alta. En la categoría Adulto es la segunda más grande y si respuesta hacia el alta es muy pareja en los dos pronósticos.

**Diabetes** La diabetes es una enfermedad crónica que afecta la forma en que el cuerpo convierte los alimentos en energía. El cuerpo descompone la mayor parte de los alimentos que ingiere en azúcar (también llamada glucosa) y la libera en la sangre. Puede existir exceso de azúcar en la sangre o ausencia de azúcar en la sangre.

```
[41]: # Análisis DIABETES

print(f'DIABETES Variable min: {dataset["DIABETES"].min()}')
print(f'DIABETES Variable max: {dataset["DIABETES"].max()}')
print(f'DIABETES Variable: {dataset["DIABETES"].nunique()}')
```

```
DIABETES Variable min: DESCONOCIDO
```

```
DIABETES Variable max: si
```

```
DIABETES Variable: 3
```

```
[42]: sns.catplot(y="DIABETES", hue="NIHSS_alta_ESTABLE_O_GRAVE",
    ↪kind="count",
    palette="Set2", edgecolor=".9",
    data=dataset);
```




Figura 4.9: Análisis de NIHSS en la en la Diabetes

En este caso en la figura 4.9, solo se tomó si el paciente poseía diabetes y los datos desconocidos se tomó como otra variable.

El gráfico muestra que la mayoría de los pacientes que tienen diabetes tienen un buen pronóstico al alta. El estado Desconocido posee un pronóstico poco favorable al alta.

**Hipertensión** La hipertensión es sinónimo de enfermedades cardíacas, siendo que es la fuerza de la presión arterial que transporta los nutrientes con la sangre.

```
[43]: # Análisis DIABETES

print(f'HTA Variable min: {dataset["HTA"].min()}')
print(f'HTA Variable max: {dataset["HTA"].max()}')
print(f'HTA Variable: {dataset["HTA"].nunique()}')
```

HTA Variable min: DESCONOCIDO

HTA Variable max: si

HTA Variable: 3

```
[44]: sns.catplot(y="HTA", hue="NIHSS_alta_ESTABLE_O_GRAVE",
    ↪kind="count",
    palette="Set2", edgecolor=".9",
    data=dataset);
```




Figura 4.10: Análisis de NIHSS en la Hipertensión

El gráfico 5.2 muestra que los pacientes que poseen hipertensión son muchos y su pronóstico es similar a que estado pueden tomar.

#### 4.5.6. Binary Encoding (Codificación binaria)

Lo que hace este proceso es la transformación de variables de una columna a binario si es posible, esto solo aplica a las viables que tiene dos estados, si posee más estados no podrá aplicar [47].

```
[45]: binary_cols = [col for col in dataset.columns if
    ↪ dataset[col].dtype not in [int, float]
        and dataset[col].nunique() == 2]

def label_encoder(dataframe, binary_col):
    labelencoder = LabelEncoder()
    dataframe[binary_col] = labelencoder.
    ↪ fit_transform(dataframe[binary_col])
    return dataframe

binary_cols
```

```
[45]: ['INR_cat', 'COL. TOTAL_cat']
```

```
[46]: from sklearn.preprocessing import LabelEncoder,
    ↪ StandardScaler, RobustScaler

for col in binary_cols:
    label_encoder(dataset, col)

dataset.head()
```

	INR_cat	COL. TOTAL_cat
0	1	0
1	1	0
2	1	0
.	.	.
.	.	.
.	.	.
72	1	1
73	1	0
74	1	0

Tabla 4.11: Binary Encoding con las variables que actualmente poseen dos estados activos

### 4.5.7. Label Encoding (Codificación de etiquetas)

Estas son variables ordinales, la codificación consiste en la traducción de ese orden en una enumeración, donde cada categoría es asociada con un número natural respetando el orden implícito existente entre categorías [47].

```
[47]: labelencoder = LabelEncoder()

[48]: dataset["NIHSS_alta_cat"] = labelencoder.
      ↪fit_transform(dataset["NIHSS_alta_cat"])
dataset["GLASGOW_cat"] = labelencoder.
      ↪fit_transform(dataset["GLASGOW_cat"])
dataset["CONTEO G.B._cat"] = labelencoder.
      ↪fit_transform(dataset["CONTEO G.B._cat"])
dataset["TRIGLICERIDOS_cat"] = labelencoder.
      ↪fit_transform(dataset["TRIGLICERIDOS_cat"])
dataset["GLUCOSA_cat"] = labelencoder.
      ↪fit_transform(dataset["GLUCOSA_cat"])
dataset["EDAD_cat"] = labelencoder.
      ↪fit_transform(dataset["EDAD_cat"])
dataset["HTA"] = labelencoder.fit_transform(dataset["HTA"])
dataset["DIABETES"] = labelencoder.
      ↪fit_transform(dataset["DIABETES"])

dataset.head(5)
```

	...	GLASGOW_cat	CONTEO G.B._cat	TRIGLICERIDOS_cat	GLUCOSA_cat	EDAD_cat
0	...	2	0	2	3	0
1	...	1	2	2	3	0
2	...	1	2	2	2	2
.		.	.	.	.	.
.	...	.	.	.	.	.
.		.	.	.	.	.
72	...	1	2	2	3	2
73	...	1	2	2	0	0
74	...	0	0	0	0	2

Tabla 4.12: Label Encoding con las variables que actualmente poseen alguna etiqueta

En las variables de Diabetes e Hipertensión el estado 2 representa “si” y el “no” es representado con un estado 1.

#### 4.5.8. One-Hot Encoding:

Para las variables categóricas donde no existe tal relación ordinal, la codificación de enteros no es suficiente. De hecho, usar esta codificación y permitir que el modelo asuma un ordenamiento natural entre categorías puede dar como resultado un desempeño deficiente o resultados inesperados [48]. En este caso, se puede aplicar una codificación one-hot a la representación de enteros. Aquí es donde se elimina la variable codificada entera y se agrega una nueva variable binaria para cada valor entero único. En el ejemplo de la variable “color”, hay 3 categorías y, por lo tanto, se necesitan 3 variables binarias. Se coloca un valor “1” en la variable binaria para el color y valores “0” para los otros colores.

```
[49]: # One Hot Encoding
dataset = pd.get_dummies(dataset)

# Como son muchas columnas, muestro todas
pd.options.display.max_columns = 0

dataset.head(5)
```

	NIHSS_INICIO_cat_Déficit Importante	NIHSS_INICIO_cat_Déficit Mínimo	NIHSS_INICIO_cat_Grave	NIHSS_INICIO_cat_Leve (Trombolizando)	NIHSS_INICIO_cat_Moderado (Buen Pronóstico)	NIHSS_INICIO_cat Sin Déficit
0 ...	0	0	0	0	1	0
1 ...	0	0	0	1	0	0
2 ...	0	0	0	1	0	0
...	.	.	.	.	.	.
72 ...	0	0	0	1	0	0
73 ...	1	0	0	0	0	0
74 ...	0	0	0	1	0	0

Tabla 4.13: One-Hot Encoding con las variables para clasificación

## 4.6. Análisis de datos de entrada

Ahora pasaremos al punto 3 de la metodología, veremos gráficos y datos que interactuaran entre si. Nuestro interés por esta sección radica por la observación

de alguna tendencia de los datos. Crearemos dos dataset auxiliar, para observar los datos que estaban y los que incorporamos en la seccion anterior.

```
[50]: # Mostramos las variables que posee la base de datos_
      ↪ actualmente
      columns_names = dataset.columns.values
      print(columns_names)

['HTA' 'DIABETES' 'EDAD' 'GLUCOSA' 'COL. TOTAL'
 ↪ 'TRIGLICERIDOS' 'INR'
 'CONTEO G.B.' 'GLASGOW AL INICO ACV' 'NIHSS INICO ACV'
 ↪ 'NIHSS alta ACV'
 'NIHSS_alta_cat' 'NIHSS_alta_ESTABLE_O_GRAVE' 'GLASGOW_cat'
 'CONTEO G.B._cat' 'INR_cat' 'TRIGLICERIDOS_cat' 'COL.
 ↪ TOTAL_cat'
 'GLUCOSA_cat' 'EDAD_cat' 'NIHSS_INICIO_cat_Déficit'
 ↪ Importante'
 'NIHSS_INICIO_cat_Déficit Mínimo' 'NIHSS_INICIO_cat_Grave'
 'NIHSS_INICIO_cat_Leve (Trombolisando)'
 'NIHSS_INICIO_cat_Moderado (Buen Pronostico)'
 'NIHSS_INICIO_cat_Sin Déficit']

[51]: # Variables originales
      columnasOriginal = ['HTA', 'DIABETES', 'EDAD', 'GLUCOSA',
      ↪ 'COL. TOTAL', 'TRIGLICERIDOS', 'INR', 'CONTEO G.B.',
      ↪ 'GLASGOW AL INICO ACV', 'NIHSS INICO ACV', 'NIHSS alta_
      ↪ ACV']
      datasetOriginal = dataset[[*columnasOriginal]]

      datasetOriginal.head(5)
```



	HTA	DIABETES	EDAD	GLUCOSA	...	GLASGOW AL INICO ACV	NIHSS INICO ACV	NIHSS alta ACV
0	0	0	53	137,09	...	11	14	42
1	2	2	54	119,995	...	15	6	0
2	2	2	78	359,42	...	15	5	2
.	.	.	.	.	...	.	.	.
.	.	.	.	.	...	.	.	.
.	.	.	.	.	...	.	.	.
72	2	2	79	116,99	...	15	2	2
73	2	2	54	211,58	...	15	1	1
74	2	2	69	217,21	...	0	4	1

Tabla 4.14: Variables originales

```
[52]: # variables agregadas
columnasAgregadas = ['NIHSS_alta_cat',
↪ 'NIHSS_alta_ESTABLE_O_GRAVE', 'GLASGOW_cat',
↪ 'CONTEO G.B._cat', 'INR_cat', 'TRIGLICERIDOS_cat', 'COL._cat',
↪ 'TOTAL_cat',
↪ 'GLUCOSA_cat', 'EDAD_cat', 'NIHSS_INICIO_cat_Déficit_Importante',
↪ 'NIHSS_INICIO_cat_Déficit Mínimo',
↪ 'NIHSS_INICIO_cat_Grave',
↪ 'NIHSS_INICIO_cat_Leve (Trombolizando)',
↪ 'NIHSS_INICIO_cat_Moderado (Buen Pronostico)',
↪ 'NIHSS_INICIO_cat_Sin Déficit']
datasetAgregado = dataset[[*columnasAgregadas]]

datasetAgregado.head(5)
```

	NIHSS_alta_cat	NIHSS_alta_ESTABLE_O_GRAVE	GLASGOW_cat	...	NIHSS_INICIO_cat_Leve (Trombolizando)	NIHSS_INICIO_cat_Moderado (Buen Pronostico)	NIHSS_INICIO_cat_Sin Déficit
0	2	1	2	...	0	1	0
1	5	0	1	...	0	1	0
2	3	0	1	...	1	0	0
.	.	.	.	...	.	.	.
.	.	.	.	...	.	.	.
.	.	.	.	...	.	.	.
72	3	0	1	...	1	0	0
73	1	0	1	...	0	0	0
74	1	1	0	...	1	0	0

Tabla 4.15: Variables agregadas por los métodos anteriores

Se observa que ambos dataset tienen un numero de cantidades de variables similares y que la última posee datos más cercanos a lo binario.

### 4.6.1. Análisis de densidad y estimación por variable

La densidad de los datos nos da la probabilidad de que una variable tomé un valor determinado por su densidad. La importancia de la densidad radica en comprender en que valores los datos están siendo más remanentes.

```
[53]: # Análisis de densidad y estimación en los datos originales
plt.rc('legend', fontsize=7)
datasetOriginal.plot.density();
```




Figura 4.11: Análisis de densidad de variables originales con escalas

Como los datos son variados numéricamente, en el grafico no se alcanza a reflejar cada variable. Si fuera necesario deberíamos analizar en este caso cada variable por separado, siendo que este no es el caso para la mayoría de las variables. A continuación, se mostrará el grafico de densidad de los exámenes.

```
[54]: fig, axes = plt.subplots(3, 2, figsize = (10, 10))
sns.set_style('darkgrid')
```

```
fig.suptitle("Gráfico de conteo para varias características_↵
↵categorías")

# Variables muy dispersas
sns.distplot(dataset['EDAD'], bins=30, color='darkred', ↵
↵ax=axes[0, 0])
sns.distplot(dataset['GLUCOSA'], bins=30, color='darkred', ↵
↵ax=axes[0, 1])
sns.distplot(dataset['COL. TOTAL'], bins=30, ↵
↵color='darkred', ax=axes[1, 0])
sns.distplot(dataset['TRIGLICERIDOS'], bins=30, ↵
↵color='darkred', ax=axes[1, 1])
sns.distplot(dataset['INR'], bins=30, color='darkred', ↵
↵ax=axes[2, 0])
sns.distplot(dataset['CONTEO G.B.'], bins=30, ↵
↵color='darkred', ax=axes[2, 1])

plt.show();
```

Gráfico de conteo para varias características categóricas

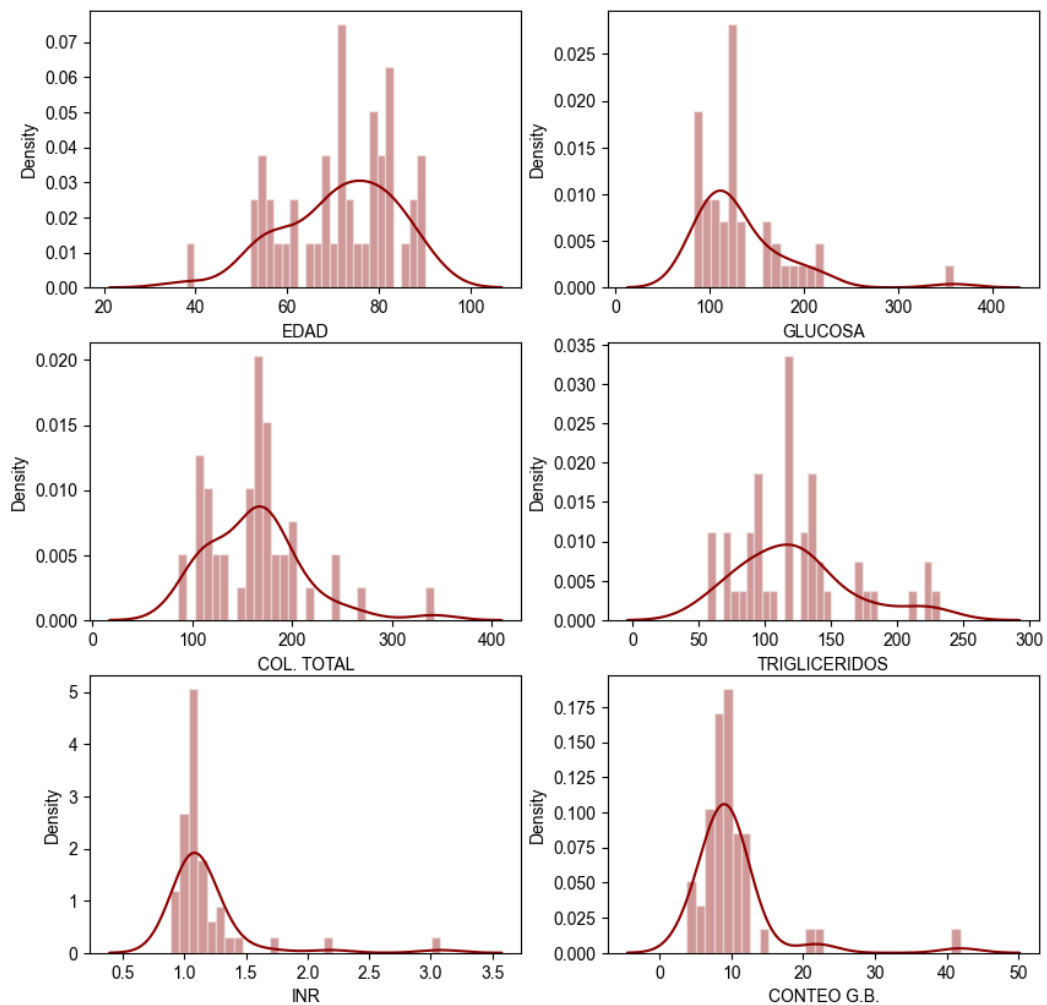


Figura 4.12: Análisis de densidad variables originales

Las tendencias de los gráficos están orientadas al grupo etario entre los 60 y 80 años estos que poseen una densidad en los datos alta, es decir que los exámenes se encuentran semejantes a los datos.

```
[55]: # Análisis de densidad y estimación en los datos agregados
plt.rc('legend', fontsize=7)
datasetAgregado.plot.density();
```




Figura 4.13: Análisis de densidad variables agregadas

Se puede interpretar el gráfico de la siguiente forma: En la variable “NIHSS\_INICIO\_cat\_Sin Déficit” la densidad de los datos es alta en el valor 0, entendiendo que esta poseía solo dos estados, 0 para confirmar que no está presente el valor y 1 para confirmar que está presente. Si lo traducimos a palabras normales, los pacientes sin déficit al principio medidos por la escala son muy pocos, la mayoría presenta déficit. El análisis individual no es necesario en este caso, ya que los valores están bien detallados a la vista, aunque estos son los valores importantes que dejó el procesamiento de datos de entrada.

#### 4.6.2. Análisis por conteo de variables categóricas

Para demostrar la cantidad de datos presente en algunas de las variables originales que son más agrupables se representará con escalas de contador por categoría.

```
[56]: fig, axes = plt.subplots(5, figsize = (5, 16))
      sns.set_style('darkgrid')
```

```
fig.suptitle("Gráfico de conteo para varias características_↵categorías originales")

sns.countplot(ax=axes[0], data=dataset, x='HTA')
sns.countplot(ax=axes[1], data=dataset, x='DIABETES')
sns.countplot(ax=axes[2], data=dataset, x='GLASGOW AL INICO_↵ACV')
sns.countplot(ax=axes[3], data=dataset, x='NIHSS INICO ACV')
sns.countplot(ax=axes[4], data=dataset, x='NIHSS alta ACV')

plt.show()
```

Gráfico de conteo para varias características categóricas originales




Figura 4.14: Análisis por conteo de variables categóricas

Las tasas de conteo de los pacientes indican una tendencia en algunos valores específicos, donde a simple vista en las escalas se encuentran en buen estado, pero la gran mayoría contiene enfermedades categóricas no transmisibles.

### 4.6.3. Distribución de Diabetes e Hipertensión

Las variables de Hipertensión y Diabetes ya poseían un valor binario como resultado, en este caso tiene un tercer valor que es el de desconocido por que son datos que no se pueden predecir.

```
[57]: fig, ax = plt.subplots(figsize=(4, 4))

sns.violinplot(
    x      = 'DIABETES',
    y      = 'NIHSS alta ACV',
    data   = dataset,
    #color = "white",
    ax     = ax
)

ax.set_title('Distribución Diabetes por NIHSS escala de_
↳alta');

fig, ax2 = plt.subplots(figsize=(4, 4))

sns.violinplot(
    x      = 'HTA',
    y      = 'NIHSS alta ACV',
    data   = dataset,
    #color = "white",
    ax     = ax2
)
```



```

ax2.set_title('Distribución Hipertensión por NIHSS escala_
↳ de alta');

fig, ax2 = plt.subplots(figsize=(4, 4))

sns.violinplot(
    x      = 'HTA',
    y      = 'DIABETES',
    data   = dataset,
    #color = "white",
    ax     = ax2
)

ax2.set_title('Distribución Hipertensión por Diabetes');

```

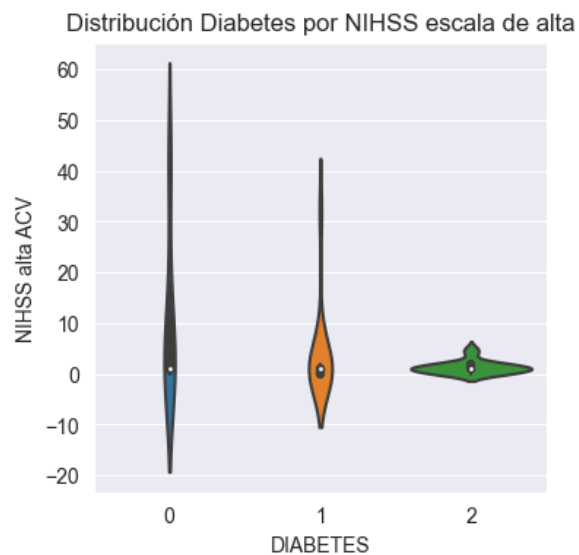


Figura 4.15: Escala de Diabetes por escala de NIHSS alta ACV




Figura 4.16: Distribución Hipertensión por escala NIHSS alta ACV

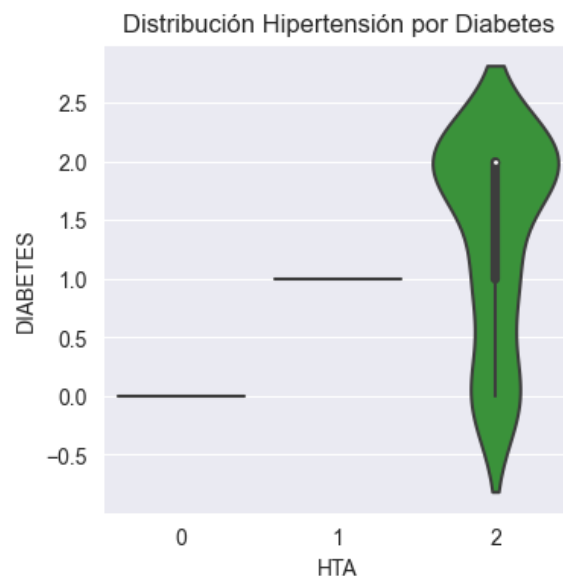


Figura 4.17: Distribución de Hipertensión sobre Diabetes

La distribución de la Diabetes e Hipertensión es inversa en la escala de alta de los pacientes. El gráfico 4.15 y 4.16 muestra que en su mayoría los pacientes que poseen diabetes tienen un pronóstico al alta más favorable, en cambio los que poseen hipertensión tienen un pronóstico menos favorable. Sin embargo, en el gráfico 4.17 la distribución de pacientes es muy pronunciada hacia que los pacientes poseen las dos enfermedades en conjunto.

#### 4.6.4. Mapa de calor de variables

Los mapas de calor pueden ayudar a visualizar el impacto de muchas categorías en los valores y son una excelente opción para ver detalles cuando se trabaja con conjuntos de datos más grandes. Los mapas de calor utilizan una variedad de colores fríos y cálidos para ayudarnos a comprender qué elementos de datos generan más interés (áreas calientes) y qué elementos se ignoran (áreas frías).

```
[58]: fig = plt.figure(figsize=(12, 8))
corr = datasetOriginal.corr()
ax = sns.heatmap(corr, linewidths=.5, cmap="RdBu",
                 annot=True, fmt="g")
```




Figura 4.18: Mapa de calor de variables originales

```
[59]: fig = plt.figure(figsize=(15, 8))
corr = datasetAgregado.corr()
```

```
ax = sns.heatmap(corr, linewidths=.5, cmap="RdBu",
                 annot=True, fmt="g")
```




Figura 4.19: Mapa de calor de variables agregadas

El primer dataset muestra un alto interés en casi todas las variables tendiendo al rojizo y algunos sectores fríos, en cambio el segundo dataset presenta variables más estables con estados más cercanos a la neutralidad.

## 4.7. Naïve Bayes - Entrenamiento del algoritmo

Este algoritmo es utilizado para predecir grandes volúmenes de datos. En este caso no se cuenta con un gran volumen de datos. El clasificador Naïve-Bayes aprende de los datos de entrenamiento y luego predice la clase de la instancia de prueba con la mayor probabilidad posterior. También es útil para datos dimensionales altos ya que la probabilidad de cada atributo se estima independientemente [49].

En el entrenamiento del algoritmo el programa de Machine Learning adquiere la información que trabajamos en los métodos anteriores. Es aquí donde se obtendrá el conocimiento para futuras decisiones, es importante asegurarse que las decisiones que sean tomadas posteriormente al proceso de entrenamiento se añadan a la base de conocimiento del algoritmo para futuras ejecuciones de este.

La BDD trabajada actualmente cuenta con:

```
[53]: print('Existen {} pacientes con {} variables.'.
      ↪format(*dataset.shape))
      print("Existen", dataset.size, "elementos")
```

Existen 46 pacientes con 26 variables.

Existen 1196 elementos

#### 4.7.1. Variable categórica

En el paso de la preparación de los datos de entrada, propusimos la variable “NIHSS alta ACV” que podía poseer 42 valores diferentes, la cual se clasificó y se transformó en “NIHSS\_alta\_cat” que contenía 6 categorías las que fueron reducidas a 1 variable con dos estados. Así el paciente tendrá un buen pronóstico o no con el nombre de la variable “NIHSS\_alta\_ESTABLE\_O\_GRAVE”. Los estudios de Machine Learning no sugieren tener variables binarias para nuestro estudio.

Las variables dependientes representan el rendimiento o conclusión que se está estudiando. Las variables independientes, además conocidas en una relación estadística como regresores, representan insumos o causas, donde se encuentran las razones potenciales de alteración.

```
[54]: # variables objetivo e independientes:
      from sklearn.model_selection import train_test_split

      # X son nuestras variables independientes
      X = dataset.drop('NIHSS_alta_ESTABLE_O_GRAVE', axis = 1)

      # y es nuestra variable dependiente
```

```
y = dataset['NIHSS_alta_ESTABLE_O_GRAVE']

# Uso de Skicit-learn para dividir datos en conjuntos de
↪entrenamiento y prueba

# División 75% de datos para entrenamiento, 25% de datos
↪para test

X_train, X_test, y_train, y_test = train_test_split(X, y,
↪random_state=0)
```

### 4.7.2. Creación del modelo y entrenamiento

Para la creación del modelo se utilizará el modelo en la forma más estándar posible, siendo que los modelos, antes del entrenamiento, pueden recibir ajustes para manejar los datos de entrada, de una forma u otra. Para que sea lo más parejo posible entre modelos se dejará de forma estándar.

```
[55]: from sklearn.naive_bayes import GaussianNB
```

```
# Creamos el modelo de NB
nb = GaussianNB()
nb.fit(X_train, y_train)
```

```
[55]: GaussianNB()
```

### 4.7.3. Predicciones sobre los datos de prueba y métricas de rendimiento

Para llevar una forma más ordenada, es necesario crear las variables de predicciones, para así sacar las métricas de rendimiento más fácilmente. Las métricas de rendimiento nos ofrecerán información de cómo se comportó el algoritmo durante el entrenamiento, dando a conocer valores importantes como lo son la precisión, exhaustividad, valor-F.

```
[56]: # Predicción Entrenamiento
prediccionEntreno = nb.predict(X_train)

# Predicción Tests
prediccionTests = nb.predict(X_test)
```

```
[57]: from sklearn import metrics

print("Entrenamiento - Presición :", metrics.
      ↪accuracy_score(y_train, prediccionEntreno))
print("Entrenamiento - Reporte de clasificación:\n",
      ↪metrics.classification_report(y_train, prediccionEntreno))
```

Entrenamiento - Presición : 0.8529411764705882

Entrenamiento - Reporte de clasificación:

	precision	recall	f1-score	support
0	0.80	1.00	0.89	20
1	1.00	0.64	0.78	14
accuracy			0.85	34
macro avg	0.90	0.82	0.84	34
weighted avg	0.88	0.85	0.85	34

La precisión de los datos de entrenamiento en el modelo tiene un valor excelente de 100 % de predicción, la exhaustividad informa la cantidad de datos capaz de identificar y en este caso es de un 100 % de los datos y finalmente el F1 combina los valores de precisión y exhaustividad obteniéndose un 100 % igual. Todos los valores mencionados aplican para los estados de la variable dependiente.

#### 4.7.4. Matriz de Confusión

En el campo de la inteligencia artificial y en especial en el problema de la clasificación estadística, una matriz de confusión es una herramienta que permite la

visualización del desempeño de un algoritmo que se emplea en aprendizaje supervisado.

```
[58]: from matplotlib import pyplot as plot
      from mlxtend.plotting import plot_confusion_matrix
      from sklearn.metrics import confusion_matrix

      matriz = confusion_matrix(y_train, prediccionEntreno)

      plot_confusion_matrix(conf_mat=matriz, figsize=(6,6),
        ↪show_normed=False)
      plot.tight_layout()
```




Figura 4.20: Matriz de confusión de entrenamiento Naive Bayes

En la matriz de confusión 4.20 (1, 1) podemos observar el resultado en el que el modelo predice correctamente la clase positiva y en el (2, 2) el resultado donde el modelo predice correctamente la clase negativa. Los demás elementos de la matriz contiene valor nulo o 0, estos son los errores de la predicción.



## 4.8. Logistic Regression - Entrenamiento del algoritmo

Este algoritmo de clasificación utilizado para predecir la probabilidad de una variable dependiente categórica. En la regresión logística, la variable dependiente es una variable binaria que contiene datos codificados como 1-0, sí-no, abierto-cerrado, etc [44].

En el entrenamiento del algoritmo el programa de Machine Learning adquiere la información que trabajamos en los métodos anteriores. Es aquí donde se obtendrá el conocimiento para futuras decisiones, es importante asegurarse que las decisiones que sean tomadas posteriormente al proceso de entrenamiento se añadan a la base de conocimiento del algoritmo para futuras ejecuciones de este.

La BDD trabajada actualmente cuenta con:

```
[54]: print('Existen {} pacientes con {} variables.'.
      ↪format(*dataset.shape))
      print("Existen", dataset.size, "elementos")
```

Existen 46 pacientes con 26 variables.

Existen 1196 elementos

### 4.8.1. Variable categórica

En el paso de la preparación de los datos de entrada, propusimos la variable “NIHSS alta ACV” que podía poseer 42 valores diferentes, la cual se clasificó y se transformó en “NIHSS\_alta\_cat” que contenía 6 categorías las que fueron reducidas a 1 variable con dos estados. Así el paciente tendrá un buen pronóstico o no con el nombre de la variable “NIHSS\_alta\_ESTABLE\_O\_GRAVE”. Los estudios de Machine Learning no sugieren tener variables binarias para nuestro estudio.

Las variables dependientes representan el rendimiento o conclusión que se está estudiando. Las variables independientes, además conocidas en una relación estadística como regresores, representan insumos o causas, donde se encuentran las razones potenciales de alteración.

```
[55]: # variables objetivo e independientes:
from sklearn.model_selection import train_test_split

# X son nuestras variables independientes
X = dataset.drop('NIHSS_alta_ESTABLE_O_GRAVE', axis = 1)

# y es nuestra variable dependiente
y = dataset['NIHSS_alta_ESTABLE_O_GRAVE']

# Uso de Skicit-learn para dividir datos en conjuntos de
↳entrenamiento y prueba
# División 75% de datos para entrenamiento, 25% de datos
↳para test
X_train, X_test, y_train, y_test = train_test_split(X, y,
↳test_size=0.8, random_state=0)
```

#### 4.8.2. Creación del modelo y entrenamiento

Para la creación del modelo se utilizará el modelo en la forma más estándar posible, siendo que los modelos, antes del entrenamiento, pueden recibir ajustes para manejar los datos de entrada, de una forma u otra. Para que sea lo más parejo posible entre modelos se dejará de forma estándar.

```
[56]: from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
↳#separa las metricas
from sklearn import metrics

# Creamos el modelo
lr = LogisticRegression(solver='lbfgs', random_state=0)
lr.fit(X_train, y_train)
```

```
[56]: LogisticRegression(random_state=0)
```

### 4.8.3. Predicciones sobre los datos de prueba y métricas de rendimiento

Para llevar una forma más ordenada, es necesario crear las variables de predicciones, para así sacar las métricas de rendimiento más fácilmente. Las métricas de rendimiento nos ofrecerán información de cómo se comportó el algoritmo durante el entrenamiento, dando a conocer valores importantes como lo son la precisión, exhaustividad, valor-F.

```
[57]: # Predicción Entrenamiento
prediccionEntreno = lr.predict(X_train)

# Predicción Tests
prediccionTests = lr.predict(X_test)
```

```
[58]: from sklearn import metrics

print("Entrenamiento - Presición :", metrics.
      ↪accuracy_score(y_train, prediccionEntreno))
print("Entrenamiento - Reporte de clasificación:\n",
      ↪metrics.classification_report(y_train, prediccionEntreno))
```

Entrenamiento - Presición : 1.0

Entrenamiento - Reporte de clasificación:

	precision	recall	f1-score	support
0	1.00	1.00	1.00	6
1	1.00	1.00	1.00	3
accuracy			1.00	9
macro avg	1.00	1.00	1.00	9
weighted avg	1.00	1.00	1.00	9

La precisión de los datos de entrenamiento en el modelo tiene un valor excelente

de 100 % de predicción, la exhaustividad informa la cantidad de datos capaz de identificar y en este caso es de un 100 % de los datos y finalmente el F1 combina los valores de precisión y exhaustividad obteniéndose un 100 % igual. Todos los valores mencionados aplican para los estados de la variable predictora.

#### 4.8.4. Matriz de Confusión

En el campo de la inteligencia artificial y en especial en el problema de la clasificación estadística, una matriz de confusión es una herramienta que permite la visualización del desempeño de un algoritmo que se emplea en aprendizaje supervisado.

```
[59]: from matplotlib import pyplot as plot
      from mlxtend.plotting import plot_confusion_matrix
      from sklearn.metrics import confusion_matrix

      matriz = confusion_matrix(y_train, prediccionEntreno)

      plot_confusion_matrix(conf_mat=matriz, figsize=(6,6),
      ↪show_normed=False)
      plot.tight_layout()
```




Figura 4.21: Matriz de confusión de entrenamiento Logistic Regression

En la matriz de confusión 4.21 (1, 1) podemos observar el resultado en el que el modelo predice correctamente la clase positiva y en el (2, 2) el resultado donde el modelo predice correctamente la clase negativa. Los demás elementos de la matriz contienen valor nulo o 0, estos son los errores de la predicción.

## 4.9. Decision Tree - Entrenamiento del algoritmo

Este algoritmo es utilizado pdecisiones te permite evaluar resultados, costos y consecuencias de una decisión compleja en grandes volúmenes datos y solventar problemas [50].

En el entrenamiento del algoritmo el programa de Machine Learning adquiere la información que trabajamos en los métodos anteriores. Es aquí donde se obtendrá el conocimiento para futuras decisiones, es importante asegurarse que las decisiones que sean tomadas posteriormente al proceso de entrenamiento se añadan a la base de conocimiento del algoritmo para futuras ejecuciones de este.

La BDD trabajada actualmente cuenta con:

```
[53]: print('Existen {} pacientes con {} variables.'.
      ↪format(*dataset.shape))
      print("Existen", dataset.size, "elementos")
```

Existen 46 pacientes con 26 variables.

Existen 1196 elementos

### 4.9.1. Variable categórica

En el paso de la preparación de los datos de entrada, propusimos la variable “NIHSS alta ACV” que podía poseer 42 valores diferentes, la cual se clasificó y se transformó en “NIHSS\_alta\_cat” que contenía 6 categorías las que fueron reducidas a 1 variable con dos estados. Así el paciente tendrá un buen pronóstico o no con el nombre de la variable “NIHSS\_alta\_ESTABLE\_O\_GRAVE”. Los estudios de Machine Learning no sugieren tener variables binarias para nuestro estudio.

Las variables dependientes representan el rendimiento o conclusión que se está estudiando. Las variables independientes, además conocidas en una relación estadística como regresores, representan insumos o causas, donde se encuentran las razones potenciales de alteración.

```
[54]: # variables objetivo e independientes:
      from sklearn.model_selection import train_test_split

      # X son nuestras variables independientes
      X = dataset.drop('NIHSS_alta_ESTABLE_O_GRAVE', axis = 1)

      # y es nuestra variable dependiente
      y = dataset['NIHSS_alta_ESTABLE_O_GRAVE']

      # Uso de Skicit-learn para dividir datos en conjuntos de
      ↪entrenamiento y prueba
      # División 75% de datos para entrenamiento, 25% de datos
      ↪para test
      X_train, X_test, y_train, y_test = train_test_split(X, y,
      ↪random_state=0)
```

#### 4.9.2. Creación del modelo y entrenamiento

Para la creación del modelo se utilizará el modelo en la forma más estándar posible, siendo que los modelos, antes del entrenamiento, pueden recibir ajustes para manejar los datos de entrada, de una forma u otra. Para que sea lo más parejo posible entre modelos se dejará de forma estándar.

```
[55]: from sklearn.tree import DecisionTreeClassifier

      # Creamos el modelo de Arbol de Decisión (y configuramos el
      ↪número máximo de nodos-hoja)
```

```
dtc = DecisionTreeClassifier(criterion = 'gini',  
    ↪random_state=0)  
dtc.fit(X_train, y_train)
```

```
[55]: DecisionTreeClassifier(random_state=0)
```

### Estructura del árbol creado

```
[56]: # Estructura del árbol creado  
from sklearn.tree import plot_tree  
  
fig, ax = plt.subplots(figsize=(13, 6))  
  
print(f"Profundidad del árbol: {dtc.get_depth()}")  
print(f"Número de nodos terminales: {dtc.get_n_leaves()}")  
  
plot = plot_tree(  
    decision_tree = dtc,  
    feature_names = feature_list,  
    class_names   = 'NIHSS_alta_ESTABLE_O_GRAVE',  
    filled        = True,  
    impurity      = False,  
    fontsize      = 10,  
    ax            = ax  
)
```

Profundidad del árbol: 3

Número de nodos terminales: 5




Figura 4.22: Árbol de decisión

### 4.9.3. Predicciones sobre los datos de prueba y métricas de rendimiento

Para llevar una forma más ordenada, es necesario crear las variables de predicciones, para así sacar las métricas de rendimiento más fácilmente. Las métricas de rendimiento nos ofrecerán información de cómo se comportó el algoritmo durante el entrenamiento, dando a conocer valores importantes como lo son la precisión, exhaustividad, valor-F.

```
[57]: # Predicción Entrenamiento
prediccionEntreno = dtc.predict(X_train)

# Predicción Tests
prediccionTests = dtc.predict(X_test)
```

```
[58]: from sklearn import metrics

print("Entrenamiento - Presición :", metrics.
      ↪accuracy_score(y_train, prediccionEntreno))

print("Entrenamiento - Reporte de clasificación:\n",
      ↪metrics.classification_report(y_train, prediccionEntreno))
```

Entrenamiento - Presición : 1.0

Entrenamiento - Reporte de clasificación:



	precision	recall	f1-score	support
0	1.00	1.00	1.00	20
1	1.00	1.00	1.00	14
accuracy			1.00	34
macro avg	1.00	1.00	1.00	34
weighted avg	1.00	1.00	1.00	34

La precisión de los datos de entrenamiento en el modelo tiene un valor excelente de 100 % de predicción, la exhaustividad informa la cantidad de datos capaz de identificar y en este caso es de un 100 % de los datos y finalmente el F1 combina los valores de precisión y exhaustividad obteniéndose un 100 % igual. Todos los valores mencionados aplican para los estados de la variable predictora.

#### 4.9.4. Matriz de Confusión

En el campo de la inteligencia artificial y en especial en el problema de la clasificación estadística, una matriz de confusión es una herramienta que permite la visualización del desempeño de un algoritmo que se emplea en aprendizaje supervisado.

```
[59]: from matplotlib import pyplot as plot
      from mlxtend.plotting import plot_confusion_matrix
      from sklearn.metrics import confusion_matrix

      matriz = confusion_matrix(y_train, prediccionEntreno)

      plot_confusion_matrix(conf_mat=matriz, figsize=(6,6),
      ↪show_normed=False)
      plot.tight_layout()
```




Figura 4.23: Matriz de confusión de entrenamiento Decision Tree

En la matriz de confusión 4.23 (1, 1) podemos observar el resultado en el que el modelo predice correctamente la clase positiva y en el (2, 2) el resultado donde el modelo predice correctamente la clase negativa. Los demás elementos de la matriz contiene valor nulo o 0, estos son los errores de la predicción.

## 4.10. Random Forest - Entrenamiento del algoritmo

Un modelo de bosque aleatorio consta de un conjunto de árboles de decisión individuales, cada uno de los cuales se entrena mediante un procedimiento de arranque para seleccionar aleatoriamente muestras de los datos de entrenamiento originales. Esto significa que cada árbol se entrena con datos ligeramente diferentes. En cada árbol individual, las observaciones se propagan a través de bifurcaciones (nodos) que generan la estructura del árbol hasta llegar a un nodo terminal [44].

En el entrenamiento del algoritmo el programa de Machine Learning adquiere la información que trabajamos en los métodos anteriores. Es aquí donde se obtendrá el conocimiento para futuras decisiones, es importante asegurarse que las decisiones que sean tomadas posteriormente al proceso de entrenamiento se añadan a la base de conocimiento del algoritmo para futuras ejecuciones de este.

La BDD trabajada actualmente cuenta con:

```
[53]: print('Existen {} pacientes con {} variables.'.
        ↪format(*dataset.shape))
print("Existen", dataset.size, "elementos")
```

Existen 46 pacientes con 26 variables.

Existen 1196 elementos

#### 4.10.1. Variable categórica

En el paso de la preparación de los datos de entrada, propusimos la variable “NIHSS alta ACV” que podía poseer 42 valores diferentes, la cual se clasificó y se transformó en “NIHSS\_alta\_cat” que contenía 6 categorías las que fueron reducidas a 1 variable con dos estados. Así el paciente tendrá un buen pronóstico o no con el nombre de la variable “NIHSS\_alta\_ESTABLE\_O\_GRAVE”. Los estudios de Machine Learning no sugieren tener variables binarias para nuestro estudio.

Las variables dependientes representan el rendimiento o conclusión que se está estudiando. Las variables independientes, además conocidas en una relación estadística como regresores, representan insumos o causas, donde se encuentran las razones potenciales de alteración.

```
[54]: # variables objetivo e independientes:
from sklearn.model_selection import train_test_split

# X son nuestras variables independientes
X = dataset.drop('NIHSS_alta_ESTABLE_O_GRAVE', axis = 1)

# y es nuestra variable dependiente
y = dataset['NIHSS_alta_ESTABLE_O_GRAVE']

# Uso de Skicit-learn para dividir datos en conjuntos de
↪entrenamiento y prueba
# División 75% de datos para entrenamiento, 25% de datos
↪para test
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y,
    ↪test_size=0.8, random_state=0)
```

### 4.10.2. Creación del modelo y entrenamiento

Para la creación del modelo se utilizará el modelo en la forma más estándar posible, siendo que los modelos, antes del entrenamiento, pueden recibir ajustes para manejar los datos de entrada, de una forma u otra. Para que sea lo más parejo posible entre modelos se dejará de forma estándar.

```
[55]: from sklearn.ensemble import RandomForestClassifier

# Creamos el modelo de Bosque Aleatorio (y configuramos el
    ↪número máximo de nodos-hoja)

rfc = RandomForestClassifier(criterion = 'gini',
    ↪random_state=0)

rfc.fit(X_train, y_train)
```

```
[55]: RandomForestClassifier(random_state=0)
```

#### Estructura del árbol creado

```
[56]: # Import tools needed for visualization
from sklearn.tree import export_graphviz
import pydot

# Pull out one tree from the forest
tree = rfc.estimators_[5]
print('The depth of this tree is:', tree.tree_.max_depth)

# Export the image to a dot file
export_graphviz(tree, out_file =
    ↪'randomForestClassification.dot', feature_names =
    ↪feature_list, rounded = True, precision = 1)
```

```
# Use dot file to create a graph
(graph, ) = pydot.
↳graph_from_dot_file('randomForestClassification.dot')

# Write graph to a png file
graph.write_png('randomForestClassification.png');
```

The depth of this tree is: 3

### 4.10.3. Predicciones sobre los datos de prueba y métricas de rendimiento

Para llevar una forma más ordenada, es necesario crear las variables de predicciones, para así sacar las métricas de rendimiento más fácilmente. Las métricas de rendimiento nos ofrecerán información de cómo se comportó el algoritmo durante el entrenamiento, dando a conocer valores importantes como lo son la precisión, exhaustividad, valor-F.

```
[57]: # Predicción Entrenamiento
prediccionEntreno = rfc.predict(X_train)

# Predicción Tests
prediccionTests = rfc.predict(X_test)
```

```
[58]: from sklearn import metrics

print("Entrenamiento - Presición :", metrics.
↳accuracy_score(y_train, prediccionEntreno))
print("Entrenamiento - Reporte de clasificación:\n",
↳metrics.classification_report(y_train, prediccionEntreno))
```

Entrenamiento - Presición : 1.0

Entrenamiento - Reporte de clasificación:

	precision	recall	f1-score	support
0	1.00	1.00	1.00	6
1	1.00	1.00	1.00	3
accuracy			1.00	9
macro avg	1.00	1.00	1.00	9
weighted avg	1.00	1.00	1.00	9

La precisión de los datos de entrenamiento en el modelo tiene un valor excelente de 100 % de predicción, la exhaustividad informa la cantidad de datos capaz de identificar y en este caso es de un 100 % de los datos y finalmente el F1 combina los valores de precisión y exhaustividad obteniéndose un 100 % igual. Todos los valores mencionados aplican para los estados de la variable predictora.

#### 4.10.4. Matriz de Confusión

En el campo de la inteligencia artificial y en especial en el problema de la clasificación estadística, una matriz de confusión es una herramienta que permite la visualización del desempeño de un algoritmo que se emplea en aprendizaje supervisado.

```
[59]: from matplotlib import pyplot as plot
      from mlxtend.plotting import plot_confusion_matrix
      from sklearn.metrics import confusion_matrix

      matriz = confusion_matrix(y_train, prediccionEntreno)

      plot_confusion_matrix(conf_mat=matriz, figsize=(6,6),
      ↪show_normed=False)
      plot.tight_layout()
```




Figura 4.24: Matriz de confusión de entrenamiento Random Forest

En la matriz de confusión 4.24 (1, 1) podemos observar el resultado en el que el modelo predice correctamente la clase positiva y en el (2, 2) el resultado donde el modelo predice correctamente la clase negativa. Los demás elementos de la matriz contienen valor nulo o 0, estos son los errores de la predicción.

# Capítulo 5

## RESULTADOS

**E**L presente capítulo tiene como finalidad la implementación del método utilizado. Los testing y usos del algoritmo nos ayudarán a observar y concluir los resultados para saber que algoritmo funciona mejor en las pruebas métricas realizadas.

### 5.1. Naïve Bayes - Testeo del algoritmo

El testing tiene la finalidad de llevar a cabo la prueba si el modelo funciona correctamente, identificando riesgos o erros que se produjeron en los datos. No se realizará ajustes posteriores al testing para poder comparar los algoritmos en la sección de resultados.

#### 5.1.1. Predicciones sobre los datos del testing y métricas de rendimiento

Ahora es momento de evaluar los datos ya entrenados con el testing. Las métricas de rendimiento nos ofrecerán información de cómo se comportó el algoritmo durante el entrenamiento, dando a conocer valores importantes como lo son la precisión, exhaustividad, valor-F.

[59]:



```
print("Tests - Precisión :", metrics.accuracy_score(y_test,
↳prediccionTests))
print("Tests - Reporte de clasificación:\n", metrics.
↳classification_report(y_test, prediccionTests))
```

Tests - Precisión : 0.5833333333333334

Tests - Reporte de clasificación:

	precision	recall	f1-score	support
0	0.55	1.00	0.71	6
1	1.00	0.17	0.29	6
accuracy			0.58	12
macro avg	0.77	0.58	0.50	12
weighted avg	0.77	0.58	0.50	12

La precisión de los datos del testing en el modelo tiene un valor de 55 % de predicción y 100 % de presicción respectivamente, la exhaustividad en el estado 0 alcanza el 100 % de los datos y en el estado 1 alcanza el 17 %. Por otra parte, el F1 combina los valores de precisión y exhaustividad obteniéndose un 71 % en el estado 0 y un 29 % en el estado 1.

Lo que se busca es la precisión del modelo, por consecuencia, el Algoritmo de Machine Learning Naïve Bayes tiene una precisión del 58.3 % de predicción.

### 5.1.2. Matriz de Confusión

Evaluaremos la matriz de confusión que se elaboró con los datos del testing.

```
[60]: matriz = confusion_matrix(y_test, prediccionTests)

plot_confusion_matrix(conf_mat=matriz, figsize=(6,6),
↳show_normed=False)
plt.tight_layout()
```




Figura 5.1: Matriz de confusión de testing Naive Bayes

En la matriz de confusión 5.1 (1 , 1) podemos observar el resultado en el que el modelo predice correctamente la clase positiva y en el (2, 2) el resultado donde el modelo predice correctamente la clase negativa. En el elemento (1, 2) el modelo predice incorrectamente la clase positiva cuando en realidad es negativa con un valor bajo y en el elemento (2, 1) el modelo predice incorrectamente la clase negativa cuando en realidad es positiva.

Las afirmaciones anteriores sugieren que la las predicciones son altas, pero también existen errores en la predicción.

## 5.2. Naïve Bayes - Uso del algoritmo

El último paso de la metodología es el uso del algoritmo, nosotros lo utilizaremos para desarrollar probabilidades en los predictores. No todos los modelos poseen los mismos métodos ni atributos, por ende, se tratará de realizar comparaciones con métodos similares entre sí.

### 5.2.1. Importancia de los predictores

Por experiencia previa y contemplando los gráficos producidos en el paso 3, sabemos que algunas características no son útiles para nuestro problema de predicción. Reducir la cantidad de funciones será la mejor alternativa, lo que acotará el tiempo de ejecución, con suerte sin comprometer significativamente el rendimiento, así podemos examinar la importancia de las funciones de nuestro modelo. La importancia de cada predictor en el modelo se calcula como la reducción total (normalizada) en el criterio de división. Si un predictor no ha sido seleccionado en ninguna división, no se ha incluido en el modelo y por lo tanto su importancia es 0.

```
[61]: # Predicciones probabilísticas
# =====
# Con .predict_proba() se obtiene, para cada observación,
# ↪ la probabilidad predicha
# de pertenecer a cada una de las dos clases.
predicciones = nb.predict_proba(X_test)
predicciones = pd.DataFrame(predicciones, columns = nb.
# ↪ classes_)
predicciones
```

	0	1
0	0,999617	0,000383
1	0,999992	8,06E-06
2	1	9,05E-08
3	0,999997	2,93E-06
4	1	4,81E-07
5	1	3,42E-07
6	0,999105	0,000895
7	0,999973	2,69E-05
8	0,999798	0,000202
9	9E-176	1
10	1	3,4E-08
11	1	0

Tabla 5.1: Predicciones probabilísticas para cada observación Bayes

Este método acepta un solo argumentos que corresponde a los datos sobre los cuales se calculan las probabilidades y devuelve una matriz de listas que contienen

las probabilidades de clase para los puntos de datos de entrada. En este caso la tabla 5.1 se observa los estados de la variable predictora tienen un valor de porcentaje predictor, por ejemplo la tupla 0 posee un 99 % y fracción de precisión para el estado 0 y un 0,11 % y fracción para el estado 1.

```
[62]: # Predicciones con clasificación final
# =====
# Con .predict() se obtiene, para cada observación, la
# ↪clasificación predicha por
# el modelo. Esta clasificación se corresponde con la clase
# ↪con mayor probabilidad.
predicciones = nb.predict(X_test)
predicciones = pd.DataFrame(predicciones)
predicciones
```

	0
0	0
1	0
2	0
3	0
4	0
5	0
6	0
7	0
8	0
9	1
10	0
11	0

Tabla 5.2: Predicciones probabilísticas con clasificación final Bayes

Se observa en la tabla 5.2 un valor binario de 0 o 1, donde se muestra cada variable desarrollada en el modelo puede tomar dicho valor. El valor 0 demuestra que la tupla no logra predecir el estado 0 de la variable predictora, y por el contrario, el estado 1 es que logra la predicción del estado en esa tupla.

### 5.3. Logistic Regression - Testeo del algoritmo

El testing tiene la finalidad de llevar a cabo la prueba si el modelo funciona correctamente, identificando riesgos o erros que se produjeron en los datos. No se realizará ajustes posteriores al testing para poder comparar los algoritmos en la sección de resultados.

#### 5.3.1. Predicciones sobre los datos del testing y métricas de rendimiento

Ahora es momento de evaluar los datos ya entrenados con el testing. Las métricas de rendimiento nos ofrecerán información de cómo se comportó el algoritmo durante el entrenamiento, dando a conocer valores importantes como lo son la precisión, exhaustividad, valor-F.

```
[60]: print("Tests - Presición :", metrics.accuracy_score(y_test,
↳prediccionTests))
print("Tests - Reporte de clasificación:\n", metrics.
↳classification_report(y_test, prediccionTests))
```

Tests - Presición : 0.5945945945945946

Tests - Reporte de clasificación:

	precision	recall	f1-score	support
0	0.59	0.80	0.68	20
1	0.60	0.35	0.44	17
accuracy			0.59	37
macro avg	0.60	0.58	0.56	37
weighted avg	0.60	0.59	0.57	37

La precisión de los datos del testing en el modelo tiene un valor de 59 % de predicción para el estado 0 y un 60 % de predicción para el estado 1. La exhaustividad en el estado 0 alcanza el 80 % de los datos y en el estado 1 alcanza solo el 35 %. Por

otra parte, el F1 combina los valores de precisión y exhaustividad obteniéndose un 68 % en el estado 0 y un 44 % en el estado 1.

Lo que se busca es la precisión del modelo, por consecuencia, el Algoritmo de Machine Learning Logistic Regression tiene una precisión del 59,4 % de predicción.

### 5.3.2. Matriz de Confusión

Evaluaremos la matriz de confusión que se elaboró con los datos del testing.

```
[61]: matriz = confusion_matrix(y_test, prediccionTests)

plot_confusion_matrix(conf_mat=matriz, figsize=(6,6),
    ↪show_normed=False)
plt.tight_layout()
```




Figura 5.2: Matriz de confusión de testing Logistic Regression

En la matriz de confusión 5.2 (1, 1) podemos observar el resultado en el que el modelo predice correctamente la clase positiva con un alto valor y en el (2, 2) el resultado donde el modelo predice correctamente la clase negativa también con un alto valor, acercándose a la misma de la clase positiva. los demás elementos de la matriz contienen valor pequeño, estos son los errores de la predicción.

Las afirmaciones anteriores sugieren que las predicciones son altas, pero también existen errores en la predicción y el principal error recae en el que el modelo predice erróneamente la clase negativa cuando en realidad es positiva.

## 5.4. Logistic Regression - Uso del algoritmo

El último paso de la metodología es el uso del algoritmo, nosotros lo utilizaremos para desarrollar probabilidades en los predictores. No todos los modelos poseen los mismos métodos ni atributos, por ende, se tratará de realizar comparaciones con métodos similares entre sí.

### 5.4.1. Importancia de los predictores

Por experiencia previa y contemplando los gráficos producidos en el paso 3, sabemos que algunas características no son útiles para nuestro problema de predicción. Reducir la cantidad de funciones será la mejor alternativa, lo que acortará el tiempo de ejecución, con suerte sin comprometer significativamente el rendimiento, así podemos examinar la importancia de las funciones de nuestro modelo. La importancia de cada predictor en el modelo se calcula como la reducción total (normalizada) en el criterio de división. Si un predictor no ha sido seleccionado en ninguna división, no se ha incluido en el modelo y por lo tanto su importancia es 0.

```
[62]: # Predicciones probabilísticas
#
# =====
# Con .predict_proba() se obtiene, para cada observación,
# la probabilidad predicha
# de pertenecer a cada una de las dos clases.
predicciones = lr.predict_proba(X_test)
predicciones = pd.DataFrame(predicciones, columns = lr.
    classes_)
predicciones
```

	0	1
0	1	9,89E-09
1	1	1,87E-09
2	0,953234	0,046766
3	0,999837	0,000163
4	0,81622	0,18378
5	0,999932	6,77E-05
6	0,024484	0,975516
7	0,998096	0,001904
8	0,778886	0,221114
9	3,58E-05	0,999964
10	0,980607	0,019393
11	0,996999	0,003001
12	0,994224	0,005776
13	0,999994	6,21E-06
14	1	1,53E-15
15	0,14296	0,85704
16	0,002332	0,997668
17	0,001081	0,998919
18	0,005275	0,994725
19	0,999973	2,7E-05
20	0,99179	0,00821
21	0,955307	0,044693
22	0,738349	0,261651
23	0,998427	0,001573
24	0,980207	0,019793
25	1	2,92E-11
26	0,080143	0,919857
27	0,000833	0,999167
28	0,999996	4,44E-06
29	0,949616	0,050384
30	0,99181	0,00819
31	0,99011	0,00989
32	0,998938	0,001062
33	1	8,15E-16
34	5,28E-05	0,999947
35	0,999998	2E-06
36	0,037317	0,962683

Tabla 5.3: Predicciones probabilísticas para cada observación Logistic Regression

Este método acepta un solo argumento que corresponde a los datos sobre los cuales se calculan las probabilidades y devuelve una matriz de listas que contienen las probabilidades de clase para los puntos de datos de entrada. En este caso la tabla 5.3 podemos observar que los estados de la variable predictora tienen un valor de porcentaje predictor, por ejemplo la tupla 0 posee un 100 % de precisión para el



estado 0 y un 0,98 % y fracción para el estado 1.

```
[63]: # Predicciones con clasificación final
#
# =====
# Con .predict() se obtiene, para cada observación, la
# clasificación predicha por
# el modelo. Esta clasificación se corresponde con la clase
# con mayor probabilidad.
predicciones = lr.predict(X_test)
predicciones = pd.DataFrame(predicciones)
predicciones
```

	<b>0</b>
<b>0</b>	0
<b>1</b>	0
<b>2</b>	0
<b>3</b>	0
<b>4</b>	0
<b>5</b>	0
<b>6</b>	1
<b>7</b>	0
<b>8</b>	0
<b>9</b>	1
<b>10</b>	0
<b>11</b>	0
<b>12</b>	0
<b>13</b>	0
<b>14</b>	0
<b>15</b>	1
<b>16</b>	1
<b>17</b>	1
<b>18</b>	1
<b>19</b>	0
<b>20</b>	0
<b>21</b>	0
<b>22</b>	0
<b>23</b>	0
<b>24</b>	0
<b>25</b>	0
<b>26</b>	1
<b>27</b>	1
<b>28</b>	0
<b>29</b>	0
<b>30</b>	0
<b>31</b>	0
<b>32</b>	0
<b>33</b>	0
<b>34</b>	1
<b>35</b>	0
<b>36</b>	1

Tabla 5.4: Predicciones probabilísticas con clasificación final Logistic Regression

Se observa en la tabla 5.4 un valor binario de 0 o 1, donde se muestra cada variable desarrollada en el modelo puede tomar dicho valor. El valor 0 demuestra que

la tupla no logra predecir el estado 0 de la variable predictora, y por el contrario, el estado 1 es que logra la predicción del estado en esa tupla.

## 5.5. Decision Tree - Testeo del algoritmo

El testing tiene la finalidad de llevar a cabo la prueba si el modelo funciona correctamente, identificando riesgos o erros que se produjeron en los datos. No se realizará ajustes posteriores al testing para poder comparar los algoritmos en la sección de resultados.

### 5.5.1. Predicciones sobre los datos del testing y métricas de rendimiento

Ahora es momento de evaluar los datos ya entrenados con el testing. Las métricas de rendimiento nos ofrecerán información de cómo se comportó el algoritmo durante el entrenamiento, dando a conocer valores importantes como lo son la precisión, exhaustividad, valor-F.

```
[60]: print("Tests - Presición :", metrics.accuracy_score(y_test, _  
      ↪prediccionTests))  
      print("Tests - Reporte de clasificación:\n", metrics.  
      ↪classification_report(y_test, prediccionTests))
```

Tests - Presición : 0.8333333333333334

Tests - Reporte de clasificación:

	precision	recall	f1-score	support
0	0.83	0.83	0.83	6
1	0.83	0.83	0.83	6
accuracy			0.83	12
macro avg	0.83	0.83	0.83	12
weighted avg	0.83	0.83	0.83	12

La precisión de los datos del testing en el modelo tiene un valor de 83 % en ambos estados. La exhaustividad en el estado 0 alcanza un 83 %. Por otra parte, el F1 combina los valores de precisión y exhaustividad obteniéndose un 83 %.

Lo que se busca es la precisión del modelo, por consecuencia, el Algoritmo de Machine Learning Decision Tree tiene una precisión del 83,3 % de predicción.

### 5.5.2. Matriz de Confusión

Evaluaremos la matriz de confusión que se elaboró con los datos del testing.

```
[61]: matriz = confusion_matrix(y_test, prediccionTests)

plot_confusion_matrix(conf_mat=matriz, figsize=(6,6),
    ↪show_normed=False)
plt.tight_layout()
```




Figura 5.3: Matriz de confusión de testing Decision Tree

En la matriz de confusión 5.3 (1, 1) podemos observar el resultado en el que el modelo predice correctamente la clase positiva con un alto valor y en el (2, 2) el resultado donde el modelo predice correctamente la clase negativa también con un

alto valor, acercándose a la misma de la clase positiva. Los demás elementos de la matriz contienen valor pequeño, estos son los errores de la predicción.

Las afirmaciones anteriores sugieren que la las predicciones son altas y el error es muy pequeño en la predicción.

## 5.6. Decision Tree - Uso del algoritmo

El último paso de la metodología es el uso del algoritmo, nosotros lo utilizaremos para desarrollar probabilidades en los predictores. No todos los modelos poseen los mismos métodos ni atributos, por ende, se tratará de realizar comparaciones con métodos similares entre sí.

### 5.6.1. Importancia de los predictores

Por experiencia previa y contemplando los gráficos producidos en el paso 3, sabemos que algunas características no son útiles para nuestro problema de predicción. Reducir la cantidad de funciones será la mejor alternativa, lo que acotará el tiempo de ejecución, con suerte sin comprometer significativamente el rendimiento, así podemos examinar la importancia de las funciones de nuestro modelo. La importancia de cada predictor en el modelo se calcula como la reducción total (normalizada) en el criterio de división. Si un predictor no ha sido seleccionado en ninguna división, no se ha incluido en el modelo y por lo tanto su importancia es 0.

```
[62]: # Predicciones probabilísticas
# =====
# Con .predict_proba() se obtiene, para cada observación,
# ↪ la probabilidad predicha
# de pertenecer a cada una de las dos clases.
predicciones = dtc.predict_proba(X_test)
predicciones = pd.DataFrame(predicciones, columns = dtc.
# ↪ classes_)
predicciones
```

	0	1
0	0	1
1	1	0
2	1	0
3	1	0
4	0	1
5	0	1
6	0	1
7	1	0
8	0	1
9	0	1
10	1	0
11	1	0

Tabla 5.5: Predicciones probabilísticas para cada observación Decision Tree

Según la tabla 5.5 la predicción probabilística en los estados 0 y 1 tuvo éxito al momento de la desición. Los resultados arrojados son exactos.

```
[63]: # Predicciones con clasificación final
# =====
# Con .predict() se obtiene, para cada observación, la
# ↪clasificación predicha por
# el modelo. Esta clasificación se corresponde con la clase
# ↪con mayor probabilidad.
predicciones = dtc.predict(X_test)
predicciones = pd.DataFrame(predicciones)
predicciones
```

	<b>0</b>
<b>0</b>	1
<b>1</b>	0
<b>2</b>	0
<b>3</b>	0
<b>4</b>	1
<b>5</b>	1
<b>6</b>	1
<b>7</b>	0
<b>8</b>	1
<b>9</b>	1
<b>10</b>	0
<b>11</b>	0

Tabla 5.6: Predicciones probabilísticas con clasificación final Decision Tree

Se observa en la tabla 5.6 un valor binario de 0 o 1, donde se muestra cada variable desarrollada en el modelo puede tomar dicho valor. El valor 0 demuestra que la tupla no logra predecir el estado 0 de la variable predictora, y por el contrario, el estado 1 es que logra la predicción del estado en esa tupla. Como reflejo de la tabla, existe un gran poder de predicción.

```
[64]: importancia_predictores = pd.DataFrame(  
        {'Predictor': dataset.  
        ↪drop(columns = "NIHSS_alta_ESTABLE_O_GRAVE").columns,  
        'importancia': dtc.  
        ↪feature_importances_  
        )  
print("Importancia de los predictores en el modelo")  
print("-----")  
importancia_predictores.sort_values('importancia',  
        ↪ascending=False)
```

	Predictor	importancia
11	NIHSS_alta_cat	0,419841
10	NIHSS alta ACV	0,215873
13	CONTEO G.B._cat	0,208163
17	GLUCOSA_cat	0,156122
0	HTA	0
14	INR_cat	0
23	NIHSS_INICIO_cat_Moderado (Buen Pronostico)	0
22	NIHSS_INICIO_cat_Leve (Trombolisando)	0
21	NIHSS_INICIO_cat_Grave	0
20	NIHSS_INICIO_cat_Déficit Mínimo	0
19	NIHSS_INICIO_cat_Déficit Importante	0
18	EDAD_cat	0
16	COL. TOTAL_cat	0
15	TRIGLICERIDOS_cat	0
12	GLASGOW_cat	0
1	DIABETES	0
9	NIHSS INICO ACV	0
8	GLASGOW AL INICO ACV	0
7	CONTEO G.B.	0
6	INR	0
5	TRIGLICERIDOS	0
4	COL. TOTAL	0
3	GLUCOSA	0
2	EDAD	0
24	NIHSS_INICIO_cat_Sin Déficit	0

Tabla 5.7: Importancia de los predictores Decision Tree

```
[65]: # Get numerical feature importances
importances = list(dtc.feature_importances_)
# List of tuples with variable and importance
feature_importances = [(feature, round(importance, 2)) for
    ↪ feature, importance in zip(feature_list, importances)]
# Sort the feature importances by most important first
feature_importances = sorted(feature_importances, key =
    ↪ lambda x: x[1], reverse = True)

# Reset style
plt.style.use('fivethirtyeight')

# lista de x ubicaciones para trazar
```



```
x_values = list(range(len(importances)))

# Gráfico de barras
plt.bar(x_values, importances, orientation = 'vertical',
        color = 'r', edgecolor = 'k', linewidth = 1.2)

# Marque las etiquetas para el eje x
plt.xticks(x_values, feature_list, rotation='vertical')

# Etiquetas de eje y título
plt.ylabel('Importancia'); plt.xlabel('Variable'); plt.
    title('Importancia de Variables');
```




Figura 5.4: Importancia de los predictores en Decision Tree

Las variables que presentan gran importancia al momento de la predicción según la tabla 5.7 y el gráfico 5.4 son “NIHSS\_alta\_cat”, “NIHSS alta ACV”, “CONTEO G.B.\_cat” y “GLUCOSA\_cat” con más del 98 %, siendo que el mayor predictor esta

con un 41,9% que es “NIHSS\_alta\_cat. Se ve reflejado en el grafico la gran importancia que representan las variables mencionadas para el modelo.

### 5.6.2. Importancia acumulada

Ahora reduciremos la cantidad de funciones en uso por el modelo a solo aquellas requeridas para representar el 95% de la importancia. Se debe usar el mismo número de características en los conjuntos de entrenamiento y prueba.

```
[66]: # Lista de funciones ordenadas de mayor a menor importancia
sorted_importances = [importance[1] for importance in
    ↪ feature_importances]
sorted_features = [importance[0] for importance in
    ↪ feature_importances]

# Importancias acumulativas
cumulative_importances = np.cumsum(sorted_importances)

# Haz un gráfico de líneas
plt.plot(x_values, cumulative_importances, 'g-')

# Dibujar línea al 95% de importancia retenida
plt.hlines(y = 0.95, xmin=0, xmax=len(sorted_importances),
    ↪ color = 'r', linestyle = 'dashed')

# Formato x ticks y etiquetas
plt.xticks(x_values, sorted_features, rotation = 'vertical')

# Etiquetas de eje y título
plt.xlabel('Variable'); plt.ylabel('Importancia acumulada');
    ↪ plt.title('Importancia acumulada');
```




Figura 5.5: Importancia de los predictores acumulada en Decision Tree

```
[67]: # Encuentre el número de características para una
      ↪ importancia acumulada del 95%
      # Agregue 1 porque Python está indexado a cero
```

```
print('Número de columna para el 95 % de importancia:', np.
      where(cumulative_importances > 0.95)[0][0] + 1)
```

Número de columna para el 95 % de importancia: 4

En el gráfico 5.5 de importancia acumulada la curva se dispara con la “GLUCOSA\_cat” y se ratifica con el resultado del 95% de importancia medido anteriormente.

## 5.7. Random Forest - Testeo del algoritmo

El testing tiene la finalidad de llevar a cabo la prueba si el modelo funciona correctamente, identificando riesgos o erros que se produjeron en los datos. No se realizará ajustes posteriores al testing para poder comparar los algoritmos en la sección de resultados.

### 5.7.1. Predicciones sobre los datos del testing y métricas de rendimiento

Ahora es momento de evaluar los datos ya entrenados con el testing. Las métricas de rendimiento nos ofrecerán información de cómo se comportó el algoritmo durante el entrenamiento, dando a conocer valores importantes como lo son la precisión, exhaustividad, valor-F.

```
[60]: print("Tests - Presición :", metrics.accuracy_score(y_test,
      ↳prediccionTests))
      print("Tests - Reporte de clasificación:\n", metrics.
      ↳classification_report(y_test, prediccionTests))
```

Tests - Presición : 0.6216216216216216

Tests - Reporte de clasificación:

	precision	recall	f1-score	support
0	0.61	0.85	0.71	20
1	0.67	0.35	0.46	17

accuracy			0.62	37
macro avg	0.64	0.60	0.58	37
weighted avg	0.63	0.62	0.59	37

La precisión de los datos del testing en el modelo tiene un valor de 61 % de predicción para el estado 0 y un 67 % de predicción para el estado 1. La exhaustividad en el estado 0 alcanza el 85 % de los datos y en el estado 1 alcanza solo el 35 %. Por otra parte, el F1 combina los valores de precisión y exhaustividad obteniéndose un 71 % en el estado 0 y un 46 % en el estado 1.

Lo que se busca es la precisión del modelo, por consecuencia, el Algoritmo de Machine Learning Random Forest tiene una precisión del 62,1 % de predicción.

### 5.7.2. Matriz de Confusión

Evaluaremos la matriz de confusión que se elaboró con los datos del testing.

```
[61]: matriz = confusion_matrix(y_test, prediccionTests)

plot_confusion_matrix(conf_mat=matriz, figsize=(6,6),
    ↪show_normed=False)
plt.tight_layout()
```




Figura 5.6: Matriz de confusión de testing Random Forest

En la matriz de confusión 5.6 (1, 1) podemos observar el resultado en el que el modelo predice correctamente la clase positiva con un alto valor y en el (2, 2) el resultado donde el modelo predice correctamente la clase negativa también con un alto valor, acercándose a la misma de la clase positiva. Los demás elementos de la matriz contienen valor pequeño, estos son los errores de la predicción.

Las afirmaciones anteriores sugieren que las predicciones son altas, pero también existen errores en la predicción.

### 5.7.3. Importancia de los predictores

Por experiencia previa y contemplando los gráficos producidos en el paso 3, sabemos que algunas características no son útiles para nuestro problema de predicción. Reducir la cantidad de funciones será la mejor alternativa, lo que acortará el tiempo de ejecución, con suerte sin comprometer significativamente el rendimiento, así podemos examinar la importancia de las funciones de nuestro modelo. La importancia de cada predictor en el modelo se calcula como la reducción total (normalizada) en el criterio de división. Si un predictor no ha sido seleccionado en ninguna división, no se ha incluido en el modelo y por lo tanto su importancia es 0.

```
[62]: # Predicciones probabilísticas
# =====
# Con .predict_proba() se obtiene, para cada observación,
# ↪ la probabilidad predicha
# de pertenecer a cada una de las dos clases.
predicciones = rfc.predict_proba(X_test)
predicciones = pd.DataFrame(predicciones, columns = rfc.
# ↪ classes_)
predicciones
```



	0	1
0	0,64	0,36
1	0,74	0,26
2	0,76	0,24
3	0,74	0,26
4	0,57	0,43
5	0,62	0,38
6	0,52	0,48
7	0,65	0,35
8	0,46	0,54
9	0,32	0,68
10	0,71	0,29
11	0,75	0,25
12	0,77	0,23
13	0,67	0,33
14	0,68	0,32
15	0,7	0,3
16	0,56	0,44
17	0,37	0,63
18	0,36	0,64
19	0,57	0,43
20	0,72	0,28
21	0,57	0,43
22	0,6	0,4
23	0,64	0,36
24	0,62	0,38
25	0,5	0,5
26	0,48	0,52
27	0,43	0,57
28	0,63	0,37
29	0,52	0,48
30	0,74	0,26
31	0,48	0,52
32	0,68	0,32
33	0,61	0,39
34	0,49	0,51
35	0,57	0,43
36	0,4	0,6

Tabla 5.8: Predicciones probabilísticas para cada observación Random Forest

Este método acepta un solo argumento que corresponde a los datos sobre los cuales se calculan las probabilidades y devuelve una matriz de listas que contienen las probabilidades de clase para los puntos de datos de entrada. En este caso particular podemos observar en la tabla 5.8 que los estados de la variable predictora tienen un

valor de porcentaje predictor, por ejemplo, la tupla 0 posee un 64 % y fracción de precisión para el estado 0 y un 0,36 % y fracción para el estado 1.

En síntesis se observa que cada uno de las variables reaccionan y toma valores porcentuales a que estado del predictor pertenece.

```
[63]: # Predicciones con clasificación final
#
# =====
# Con .predict() se obtiene, para cada observación, la
# clasificación predicha por
# el modelo. Esta clasificación se corresponde con la clase
# con mayor probabilidad.
predicciones = rfc.predict(X_test)
predicciones = pd.DataFrame(predicciones)
predicciones
```

	<b>0</b>
<b>0</b>	0
<b>1</b>	0
<b>2</b>	0
<b>3</b>	0
<b>4</b>	0
<b>5</b>	0
<b>6</b>	0
<b>7</b>	0
<b>8</b>	1
<b>9</b>	1
<b>10</b>	0
<b>11</b>	0
<b>12</b>	0
<b>13</b>	0
<b>14</b>	0
<b>15</b>	0
<b>16</b>	0
<b>17</b>	1
<b>18</b>	1
<b>19</b>	0
<b>20</b>	0
<b>21</b>	0
<b>22</b>	0
<b>23</b>	0
<b>24</b>	0
<b>25</b>	0
<b>26</b>	1
<b>27</b>	1
<b>28</b>	0
<b>29</b>	0
<b>30</b>	0
<b>31</b>	1
<b>32</b>	0
<b>33</b>	0
<b>34</b>	1
<b>35</b>	0
<b>36</b>	1

Tabla 5.9: Predicciones probabilísticas con clasificación final Random Forest

Se observa en la tabla 5.9 un valor binario de 0 o 1, donde se muestra cada variable desarrollada en el modelo puede tomar dicho valor. El valor 0 demuestra que la tupla no logra predecir el estado 0 de la variable predictora, y por el contrario, el estado 1 es que logra la predicción del estado en esa tupla.

```
[64]: importancia_predictores = pd.DataFrame(  
        {'Predictor': dataset.  
        ↪drop(columns = "NIHSS_alta_ESTABLE_O_GRAVE").columns,
```

```

        'importancia': rfc.
↪feature_importances_}

    )

print("Importancia de los predictores en el modelo")
print("-----")
importancia_predictores.sort_values('importancia', ↪
↪ascending=False)

```

	Predictor	importancia
5	TRIGLICERIDOS	0,149579
2	EDAD	0,098917
9	NIHSS INICO ACV	0,087893
4	COL. TOTAL	0,079422
3	GLUCOSA	0,076047
17	GLUCOSA_cat	0,06392
16	COL. TOTAL_cat	0,060227
10	NIHSS alta ACV	0,056171
6	INR	0,054726
7	CONTEO G.B.	0,052931
13	CONTEO G.B._cat	0,050685
1	DIABETES	0,050415
8	GLASGOW AL INICO ACV	0,041865
11	NIHSS_alta_cat	0,041696
22	NIHSS_INICIO_cat_Leve (Trombolisando)	0,019722
0	HTA	0,010101
20	NIHSS_INICIO_cat_Déficit Mínimo	0,005682
23	NIHSS_INICIO_cat_Moderado (Buen Pronostico)	0
21	NIHSS_INICIO_cat_Grave	0
12	GLASGOW_cat	0
19	NIHSS_INICIO_cat_Déficit Importante	0
18	EDAD_cat	0
15	TRIGLICERIDOS_cat	0
14	INR_cat	0
24	NIHSS_INICIO_cat_Sin Déficit	0

Tabla 5.10: Importancia de los predictores Random Forest

```

[65]: # Get numerical feature importances
importances = list(rfc.feature_importances_)
# List of tuples with variable and importance
feature_importances = [(feature, round(importance, 2)) for ↪
↪feature, importance in zip(feature_list, importances)]

```

```
# Sort the feature importances by most important first
feature_importances = sorted(feature_importances, key =
    ↪ lambda x: x[1], reverse = True)

# Reset style
plt.style.use('fivethirtyeight')

# lista de x ubicaciones para trazar
x_values = list(range(len(importances)))

# Gráfico de barras
plt.bar(x_values, importances, orientation = 'vertical',
    ↪ color = 'r', edgecolor = 'k', linewidth = 1.2)

# Marque las etiquetas para el eje x
plt.xticks(x_values, feature_list, rotation='vertical')

# Etiquetas de eje y título
plt.ylabel('Importancia'); plt.xlabel('Variable'); plt.
    ↪ title('Importancia de Variables');
```




Figura 5.7: Importancia de los predictores en Random Forest

El cálculo de importancia muestra en la tabla 5.10 y en el gráfico 5.7 que existen muchas variables con importancia al momento de la predicción, siendo la que destaca “TRIGLICERIDOS” con un 14,9 % de importancia. Viendo el grafico, se observa que aún hay variables que no son significantes.

### 5.7.4. Importancia acumulada

Ahora reduciremos la cantidad de funciones en uso por el modelo a solo aquellas requeridas para representar el 95 % de la importancia. Se debe usar el mismo número de características en los conjuntos de entrenamiento y prueba.

```
[66]: # Lista de funciones ordenadas de mayor a menor importancia
sorted_importances = [importance[1] for importance in
    ↪ feature_importances]

sorted_features = [importance[0] for importance in
    ↪ feature_importances]

# Importancias acumulativas
cumulative_importances = np.cumsum(sorted_importances)

# Haz un gráfico de líneas
plt.plot(x_values, cumulative_importances, 'g-')

# Dibujar línea al 95% de importancia retenida
plt.hlines(y = 0.95, xmin=0, xmax=len(sorted_importances),
    ↪ color = 'r', linestyle = 'dashed')

# Formato x ticks y etiquetas
plt.xticks(x_values, sorted_features, rotation = 'vertical')

# Etiquetas de eje y título
plt.xlabel('Variable'); plt.ylabel('Importancia acumulada');
    ↪ plt.title('Importancia acumulada');
```




Figura 5.8: Importancia de los predictores acumulada en Random Forest

```
[67]: # Encuentre el número de características para una
      ↪ importancia acumulada del 95%
      # Agregue 1 porque Python está indexado a cero
```



```
print('Número de columna para el 95 % de importancia:', np.  
      ↳where(cumulative_importances > 0.95)[0][0] + 1)
```

Número de columna para el 95 % de importancia: 14

En el gráfico ?? la curva se dispara con la “GLASGOW AL INICO ACV” y se ratifica con el resultado del 95 % de importancia medido anteriormente con el valor cercano del 95 % de importancia acumulada de los datos.

## Capítulo 6

# DISCUSIONES, CONCLUSIONES Y RECOMENDACIONES

En la investigación se realizó un estudio sobre exámenes o resultados de pacientes post Accidente Cerebrovascular del hospital Herminda Martin de Chillán por medio de técnicas de Machine Learning. La recopilación de datos de los pacientes fue una colaboración entre la investigadora e Informática Dra. Carolina Figueroa con el médico e investigador Dr. Carlos Escudero.

Por medio del trabajo, se concluye que existe relación entre el estado de alta del paciente y los datos que están en la base de datos, lo cual ha sido confirmado por los modelos de Machine Learning. Asimismo, los resultados son menores en relación con investigaciones anteriores, las cuales fueron expuestas en los trabajos relacionados, bordeando el promedio de predicción en un 90 % para las otras investigaciones y el mejor modelo elaborado en este trabajo un 83 %. Este resultado prueba la validez de la hipótesis de la investigación, asimismo, permite determinar la técnica de Machine Learning más precisa, con el fin de clasificar según el tipo de secuela a los pacientes que han sufrido ACV Isquémico del Hospital Herminda Martín. En otras palabras, la clasificación para conocer si un paciente tendrá un pronóstico de secuelas que le permitan tener un buen diario vivir o no, a través del modelo más confiable que es en este caso Decision Tree con un 83 % de probabilidades de precisión.

Para investigar las técnicas clásicas de Machine Learning se lograron estudiar varios modelos que fueron expuesto en el Marco Teórico y aplicaciones en los Trabajos Relacionados. Las técnicas con algoritmos supervisado existían más trabajos que estaban aplicados en la salud. Debe señalarse que el Deep Learning era la mejor opción, pero no se podía aplicar por escasos de datos que se poseía.

En resumidas cuentas, las técnicas eran muy variadas y su utilización estaba optimizada en muchos casos con hiperparametros, aunque los modelos que más aparecieron en la literatura fueron Logistic Regression, Naive Bayes, Decision Tree y Random Forest, siendo que estos algoritmos se desenvuelven bien en problemáticas de salud y algunos actúan mejor con variables binarias para una mejor predicción.

Se estableció que el mecanismo para que el modelo llegará a poder predecir debía ser sacado de la literatura e investigaciones en salud de Machine Learning de código libre, en este caso particular se guio la investigación por el libro “Machine Learning in Action” en su metodología y varios procesos de clasificaciones de datos.

Se determino que las variables de Hipertensión y Diabetes eran significativas para la investigación descrito en el capítulo 4 en la Dispersión de HTA y Diabetes respecto a la escala NISS de alta. Se demostró que las variables creadas en el proceso tenían una similitud parecida en importancia y que las que ya existían lo poseían también. Dependiendo el modelo hay variables que poseían mayor importancia para la predicción, como es el ejemplo de Decision Tree que contaba con la importancia más alta en la variable creada y procesada de “NIHSS\_alta\_cat” con un 41 %, la seguía “NIHSS alta ACV” con un 21 %. En cambio, Random Forest su variable más importante era “TRIGLICERIDOS” con un 14% y lo seguía la “EDAD” con un 9 %.

En cuanto a la comparativa de las técnicas de Machine Learning, en primera instancia con qué estado tenían un mejor desempeño, siendo que en el estado de Pronóstico Favorable el ganador fue “Decision Tree” con 249 puntos de 300 totales,

destacamos que los resultados estuvieron parejos en este estado y en el estado de Pronóstico poco Favorable el ganador fue “Decision Tree” arrasando ante sus competidores con los mismo 249 puntos sobre 300. En segunda instancia, la comparación final solo se tomo en cuenta la métrica de la Precisión Acumulada, también llevándose el primer lugar “Decision Tree” con un 83 % sobre su competidor más cercano Random Forest con un 62 % de predicción de los datos.

En el Procesamiento de los datos se utilizaron técnicas de clasificación de Missing Data, Clasificaciones propias de las variables, Label Encoding, entre otras, que proponen disminuir la perdida de datos, darle etiquetas a los valores y las etiquetas asignarles valores numéricos, respectivamente. El One-Hot Encoding es una técnica que en la mayoría de las modelos de ML de clasificación es usa como paso anterior al entrenamiento de los datos en el modelo, eliminando la variable codificada entera y se agrega una nueva variable binaria para cada valor entero único, ayudando a que las variables pasen a un estado binario. Cabe concluir, que este trabajo se enfocó en representar a los pacientes para tener una esperanza favorable o menos favorable en la escala NIHSS, contemplando el daño neurológico en los pacientes post ACV Isquémico, dando como resultado general que la mayoría de los pacientes post ACV Isquémico tendrán un pronóstico favorable cuando están de alta, enfatizamos que el alta no indica que el paciente se encuentre bien de salud, ya que el daño neurológico corresponde a perdida cognoscitiva o motor. Señalamos que aunque la muestra fue pequeña, se pueden obtener resultados en las posibles variables de importancia para nuevos trabajos investigativos en el campo de la medicina y Machine Learning.

Finalmente, los aportes de la IIA a la medicina pueden ser un cambio que favorecerá para la respuesta más instantánea de la toma de decisiones de los médicos, pero debe haber una cooperación entre ambos campos de manera abierta, con inversiones para la salud, contando con equipos de trabajos y bases de datos gigantescas pero bien clasificadas como se menciona en los trabajos relacionados, esto llevará a poder dar un mejor pronóstico teniendo en cuenta que los equipos multidisciplinarios realizan grandes avances e involucran más aspectos que son necesarios para evaluar el sistema completo que lo compone a la persona.

# Bibliografía

- [1] I. Ortiz-Galeano, N. E. F. Balmaceda, and A. Flores, "Cardiovascular risk factors in patients with stroke," *Revista Virtual de la Sociedad Paraguaya de Medicina Interna*, vol. 7, pp. 50–55, 3 2020.
- [2] C. M. de Salud, "Ataque cerebrovascular - ministerio de salud - gobierno de chile," 2022.
- [3] J. Gaudiano, D. Graña, M. Goñi, V. Colina, A. Cosentino, R. Pensado, V. Ruglio, M. Scaron, L. Vidart, J. Gaudiano, D. Graña, M. Goñi, V. Colina, A. Cosentino, R. Pensado, V. Ruglio, M. Scaron, and L. Vidart, "Epidemiológica del ataque cerebro vascular en un hospital universitario," *Revista Uruguaya de Medicina Interna*, vol. 4, pp. 24–31, 7 2019.
- [4] E. C. Rodríguez, A. S. Fernández, A. G. González, M. G. Camejo, and Y. F. Viltres, "Características de los pacientes con enfermedad cerebrovascular," *Multi-med*, 2020.
- [5] S. de Salud de Ñuble, "El 80 % de los casos de ataque cerebrovascular se pueden prevenir," 10 2018.
- [6] W. H. Curioso and M. J. Brunette, "Artificial intelligence and innovation to optimize the tuberculosis diagnostic process," *Revista Peruana de Medicina Experimental y Salud Publica*, vol. 37, pp. 554–558, 7 2020.
- [7] S. Grazia and T. Vizoso, "Reflexiones sobre la inteligencia artificial y la bibliotecología reflections on artificial intelligence and librarianship," 2022.
- [8] C. F. Flores, *Visual Saliency for Object Recognition, and Object Recognition for Visual Saliency*. 2 2021.

- [9] "Conceptos básicos (redes neuronales) - documentación de ibm."
- [10] M. A. Moreno Herrera and M. G. Reyes Maldonado, *Diseño de una aplicación de data science para la predicción del rendimiento académico de los estudiantes de la Unidad Educativa "José Elías Altamirano", año 2021*. PhD thesis, Universidad de Guayaquil. Facultad de Ciencias Matemáticas y Físicas ..., 2021.
- [11] W. J. Murdoch, C. Singh, K. Kumbier, R. Abbasi-Asl, and B. Yu, "Interpretable machine learning: definitions, methods, and applications," *arXiv preprint arXiv:1901.04592*, 2019.
- [12] K. Teknomo and M. R. Estuar, "Visualización de patrones de paso de individuos con y sin discapacidad con el uso de acelerometría en teléfonos inteligentes," *Revista Colombiana de Estadística*, vol. 37, pp. 471–488, 2015.
- [13] P. Harrington, *Machine Learning in Action*. manning publications ed., 2012.
- [14] G. S. S. R. I. de Statistique and undefined 1985, "Conditional probability," *JS-TOR*.
- [15] K. Vembandasamy, R. Sasipriya, E. D. I. J. of, and undefined 2015, "Heart diseases detection using naive bayes algorithm," *ijiset.com*, vol. 2, 2015.
- [16] J. C. Stoltzfus, "Logistic regression: A brief primer," *Academic Emergency Medicine*, vol. 18, pp. 1099–1104, 10 2011.
- [17] D. Dantas, M. De, C. Nunes, S. Terra, L. Paulo, B. Schorr, and N. Calegario, "Machine learning for carbon stock prediction in a tropical forest in southeastern brazil," *BOSQUE*, vol. 42, pp. 131–140, 2021.
- [18] R. Salas, "Redes neuronales artificiales," *Universidad de Valparaíso. Departamento de Computación*, vol. 1, pp. 1–7, 2004.
- [19] R. A. Borracci, C. C. Higa, G. Ciambone, and J. Gambarte, "Treatment of individual predictors with neural network algorithms improves global registry of acute coronary events score discrimination el tratamiento con redes neuronales de las variables del global registry of acute coronary mejora la discriminación del score correspondence," *Arch Cardiol Mex*, vol. 91, pp. 58–65, 2021.

- [20] J. F. P. BARRERA, I. Mecatrónica, D. A. Hurtado, and R. J. Moreno, "Prediction system of erythemas for phototypes i and ii, using deep-learning sistema de predicción de eritema para fototipo i y ii, utilizando deep-learning," vol. 22, pp. 188–196, 2015.
- [21] C. Arana, "Redes neuronales recurrentes: Análisis de los modelos especializados en datos secuenciales," tech. rep., Serie Documentos de Trabajo, 2021.
- [22] S. Pang, Z. Yu, and M. A. Orgun, "A novel end-to-end classifier using domain transferred deep convolutional neural networks for biomedical images," *Computer methods and programs in biomedicine*, vol. 140, pp. 283–293, 3 2017.
- [23] C. Dong, C. Shao, J. Li, and Z. Xiong, "An improved deep learning model for traffic crash prediction," *Journal of Advanced Transportation*, vol. 2018, 2018.
- [24] J. A. Peña-Torres, R. E. Gutiérrez, V. A. Bucheli, and F. A. González, "How to adapt deep learning models to a new domain: The case of biomedical relation extraction cómo adaptar un modelo de aprendizaje profundo a un nuevo dominio: el caso de la extracción de relaciones biomédicas how to adapt deep learning models to a new domain: The case of biomedical relation extraction," vol. 22, pp. 49–62, 2019.
- [25] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," 2015.
- [26] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," in *Advances in Neural Information Processing Systems* (F. Pereira, C. Burges, L. Bottou, and K. Weinberger, eds.), vol. 25, Curran Associates, Inc., 2012.
- [27] L. Fei-Fei, R. Fergus, and P. Perona, "One-shot learning of object categories," 2006.
- [28] V. Astudillo and D. Revelo, "Apoyo al diagnóstico de neumonía y detección de opacidades pulmonares usando segmentación de instancias semánticas en imágenes de rayos x de tórax," vol. 39, pp. 259–274, 2021.

- [29] C. G. Alfonso, A. E. M. Reyes, V. García, A. R. Fajardo, I. Torres, and J. C. Casas, "Actualización en diagnóstico y tratamiento del ataque cerebrovascular isquémico agudo," *Universitas Médica*, vol. 60, pp. 1–17, 6 2019.
- [30] H. P. Adams, B. H. Bendixen, L. J. Kappelle, J. Biller, B. B. Love, D. L. Gordon, and E. E. Marsh, "Classification of subtype of acute ischemic stroke. definitions for use in a multicenter clinical trial. toast. trial of org 10172 in acute stroke treatment.," *Stroke*, vol. 24, pp. 35–41, 1 1993.
- [31] J. M. Seguin, A. B. Vena, L. C. Campàs, I. Benalbdelhak, and F. P. García, "Revisión sistemática de las características y pronóstico de los sujetos que sufren un ictus criptogénico no lacunar de mecanismo embólico," *Revista de Neurología*, vol. 66, p. 325, 2018.
- [32] R. A. Radu, E. O. Terecoasă, O. A. Băjenaru, and C. Tiu, "Etiologic classification of ischemic stroke: Where do we stand?," *Clinical Neurology and Neurosurgery*, vol. 159, pp. 93–106, 8 2017.
- [33] A. P. Cruz, B. S. Rivero, and J. C. E. Parlay, "Diagnóstico clínico y tomográfico en la enfermedad cerebrovascular," *Archivos del Hospital Universitario General Calixto García*, 2020.
- [34] M. Wintermark, P. C. Sanelli, G. W. Albers, J. Bello, C. Derdeyn, S. W. Hetts, M. H. Johnson, C. Kidwell, M. H. Lev, D. S. Liebeskind, H. Rowley, P. W. Schaefer, J. L. Sunshine, G. Zaharchuk, and C. C. Meltzer, "Imaging recommendations for acute stroke and transient ischemic attack patients: A joint statement by the american society of neuroradiology, the american college of radiology, and the society of neurointerventional surgery," 2013.
- [35] M. Nagendran, Y. Chen, C. A. Lovejoy, A. C. Gordon, M. Komorowski, H. Harvey, E. J. Topol, J. P. A. Ioannidis, G. S. Collins, and M. Maruthappu, "Artificial intelligence versus clinicians: systematic review of design, reporting standards, and claims of deep learning studies," *BMJ*, p. m689, 3 2020.
- [36] J. N. Heo, J. G. Yoon, H. Park, Y. D. Kim, H. S. Nam, and J. H. Heo, "Machine learning-based model for prediction of outcomes in acute stroke," *Stroke*, vol. 50, pp. 1263–1265, 5 2019.



- [37] D. Scrutinio, C. Ricciardi, L. Donisi, E. Losavio, P. Battista, P. Guida, M. Cesarelli, G. Pagano, and G. D'Addio, "Machine learning to predict mortality after rehabilitation among patients with severe stroke," *Scientific Reports* 2020 10:1, vol. 10, pp. 1–10, 11 2020.
- [38] J. Yu, S. Park, H. Lee, C. S. Pyo, and Y. S. Lee, "An elderly health monitoring system using machine learning and in-depth analysis techniques on the nih stroke scale," *Mathematics* 2020, Vol. 8, Page 1115, vol. 8, p. 1115, 7 2020.
- [39] Y. Xie, B. Jiang, E. Gong, Y. Li, G. Zhu, P. Michel, M. Wintermark, and G. Zaharchuk, "Use of gradient boosting machine learning to predict patient outcome in acute ischemic stroke on the basis of imaging, demographic, and clinical information," <https://doi.org/10.2214/AJR.18.20260>, vol. 212, pp. 44–51, 10 2018.
- [40] R. Bioética, H. D. C. Nunes, R. M. C. Guimarães, and L. Dadalto, "Desafios bioéticos do uso da inteligência artificial em hospitais," *Revista Bioética*, vol. 30, pp. 82–93, 5 2022.
- [41] C. S. Shao, Z. X. Xiong, C. D. Dong, C. Dong, and J. L. Li, "An improved deep learning model for traffic crash prediction," 2018.
- [42] M. Kumar, "Project management in data science using osemn | by mukesh kumar | insaid | medium," 2022.
- [43] H. Bar, "Missing data — mechanisms and possible solutions / datos ausentes: mecanismos y posibles soluciones," <https://doi.org/10.1080/11356405.2017.1365426>, vol. 29, pp. 492–525, 2017.
- [44] F. B. Pareja, J. D. Guzmán, and J. Porta-Etessam, "Cien escalas de interés en neurología clínica," 2001.
- [45] B. C. Meyer and P. D. Lyden, "The modified national institutes of health stroke scale (mnhss): Its time has come," *International journal of stroke : official journal of the International Stroke Society*, vol. 4, p. 267, 2009.
- [46] "Conteo de glóbulos blancos - serie—resultados: Medlineplus enciclopedia médica."

- [47] J. T. Hancock and T. M. Khoshgoftaar, "Survey on categorical data for neural networks," *Journal of Big Data*, vol. 7, pp. 1–41, 12 2020.
- [48] R. E. Bank and C. C. Douglas, "Sparse matrix multiplication package (smmp)," *Advances in Computational Mathematics*, vol. 1, pp. 127–137, 2 1993.
- [49] R. Mosquera, O. D. Castrillón, L. Parra, R. Mosquera, O. D. Castrillón, and L. Parra, "Máquinas de soporte vectorial, clasificador naïve bayes y algoritmos genéticos para la predicción de riesgos psicosociales en docentes de colegios públicos colombianos," *Información tecnológica*, vol. 29, pp. 153–162, 12 2018.
- [50] J. Sulla-Torres, R. Gómez-Campos, M. Cossio-Bolaños, J. Sulla-Torres, R. Gómez-Campos, and M. Cossio-Bolaños, "Aplicación de un árbol de decisión difusa con clasificación de ambigüedad para determinar el exceso de peso en escolares," *Revista mexicana de ingeniería biomédica*, vol. 39, pp. 128–143, 2018.